Universidad de Chile
Facultad de Ciencias Físicas y Matemáticas
Departamento de Ingeniería Industrial

DISEÑO DE POLÍTICAS COMERCIALES PARA UNA EMPRESA DE TECNOLOGÍA PARA SERVICIOS DE SALUD BASADO EN EL COMPORTAMIENTO DE SUS CLIENTES

Integrantes: Christopher Lagos
Profesores: Loreto Martínez G.
Maximo Bosch P.
Nicolás Fritis C.

Fecha de entrega: 1 de diciembre de 2025
Santiago de Chile

Resumen Ejecutivo

La memoria desarrolla el proyecto “Diseño de políticas comerciales para una empresa de tecnología para servicios de salud basado en el comportamiento de sus clientes”, realizado en Reservo, proveedor chileno de software como servicio para profesionales y centros de salud pequeños y medianos con presencia en Chile, Argentina, Colombia y México. La empresa opera con cerca de 3.500 clientes activos bajo un modelo de suscripción mensual y enfrenta una tasa de bajas en torno a 2,4 por ciento, expansiones y reactivaciones poco sistemáticas y una asignación reactiva de los recursos de Customer Success. El problema central se define como una caracterización y segmentación conductual insuficiente de la cartera activa en postventa, que impide diferenciar las acciones comerciales según riesgo de baja y valor económico del cliente.

El proyecto tiene como objetivo general desarrollar un modelo analítico de segmentación conductual que permita gestionar de manera proactiva las estrategias de retención y expansión. Para ello se sigue la metodología CRISP-DM, con fases de comprensión del negocio, comprensión de los datos, preparación, modelado, evaluación y despliegue. Se construye un datamart mensual a nivel cliente–mes que integra información de contexto, valor, uso y fricción. Las principales variables son país, rubro, plan comercial, una aproximación al ingreso mensual por cliente, la antigüedad en meses, el número de citas en los últimos treinta días, la recencia de uso y los bloqueos en los últimos noventa días. La etiqueta de salida se define como una baja efectiva en el mes siguiente al corte, lo que permite formular un problema de clasificación binaria con horizonte T+1.

El panel resultante contiene 43.965 observaciones y 1.073 eventos de baja, que se dividen en conjuntos de entrenamiento, desarrollo y prueba respetando el orden temporal. Sobre esta base se entrena una regresión logística binaria con regularización y ponderación de clases, encapsulada en un flujo que incluye imputación de valores faltantes, tratamiento de extremos, transformaciones logarítmicas y codificación de variables categóricas. Las probabilidades se calibran fuera de muestra y se evalúan en un conjunto de prueba reciente. El modelo alcanza un ROC–AUC cercano a 0,825, un área bajo la curva precisión–recall aproximadamente cuatro veces superior a la tasa base de eventos y una fuerte capacidad de focalización: el 20 por ciento de clientes con mayor probabilidad estimada concentra alrededor del 70 por ciento de las bajas observadas. La calibración global es adecuada y los resultados se mantienen estables en los segmentos principales, lo que respalda el uso de un modelo global para la región.

A partir del datamart y del modelo se construye un prototipo operativo que conecta la analítica con la gestión diaria. El flujo mensual de uso combina un script SQL que genera el datamart en la base de datos de producción, un cuaderno en Google Colab que aplica el modelo calibrado sobre el corte actualizado y un archivo de Excel que presenta las probabilidades de baja, los rangos de riesgo y los datos de contexto en un formato familiar para Customer Success. Sobre esta base se propone una segmentación conductual que combina nivel de riesgo, valor económico aproximado, rubro y plan comercial, utilizando además los motivos de baja observados por rubro y por plan como guía para ajustar las acciones sugeridas en cada segmento. El portafolio inicial de políticas incluye contactos proactivos uno a

uno para clientes de alto riesgo y alto valor, campañas automatizadas para clientes de alto riesgo y menor valor, y monitoreo liviano para segmentos de riesgo medio o bajo.

La memoria cuantifica además una línea base económica que estima un ingreso mensual recurrente cercano a 205 millones de pesos chilenos y una pérdida anual de ingresos por bajas del orden de 59 millones de pesos. Sobre esta base se muestran escenarios de mejora en que reducciones moderadas de la tasa de churn se traducen en montos anuales de ingreso retenido que justifican el esfuerzo de implementación del modelo y de las políticas. El trabajo concluye que el conjunto formado por el datamart mensual, el modelo de regresión logística calibrado, la segmentación conductual enriquecida con información de motivos de baja y el prototipo operativo entrega a Reservo una herramienta concreta para priorizar clientes según riesgo, valor y contexto comercial, y para avanzar hacia una gestión de la postventa más sistemática y alineada con el impacto económico de cada decisión. Al mismo tiempo, se identifican líneas claras para trabajos futuros, como la incorporación de nuevas fuentes de datos (incluyendo visitas a los centros y métricas de satisfacción), la exploración de modelos alternativos, la automatización del flujo en la infraestructura propia de la empresa y la realización de pilotos controlados que midan de manera conjunta la efectividad y el costo de las acciones de retención y expansión.

Índice de Contenidos

1. Antecedentes generales **1**
1.1. Industria y ambiente competitivo . . . 1
1.2. Características de la empresa u organización . . . 2

2. Descripción del problema u oportunidad **4**
2.1. Antecedentes . . . 4
2.1.1. Proceso general . . . 4
2.1.2. Etapa de Captación . . . 4
2.1.3. Etapa de Ventas . . . 5
2.1.4. Etapa de Onboarding . . . 5
2.1.5. Etapa de Cliente Activo . . . 5
2.1.6. Etapa de Cliente Inactivo . . . 5
2.2. Problema encontrado . . . 6
2.2.1. Efectos y consecuencias observadas . . . 6
2.2.2. Análisis y Elección del Problema Central . . . 7
2.2.3. Causas del Problema Central . . . 8

3. Descripción y Justificación del Proyecto **9**
3.1. Definición y resultado del proyecto . . . 9
3.2. Justificación estratégica . . . 10
3.3. Evaluación económica . . . 10
3.4. Razones prácticas y técnicas . . . 11
3.5. Elección del enfoque . . . 12

4. Alcance **13**

5. Objetivos del proyecto **14**
5.1. Objetivo general . . . 14
5.2. Objetivos específicos . . . 14
5.3. Indicadores de éxito . . . 14

6. Marco Conceptual **16**
6.1. Fundamentos de CRM orientado a valor . . . 16
6.2. Herramientas de ingeniería y analítica aplicadas . . . 16
6.3. Evaluación económica y métricas de desempeño . . . 17
6.4. Elección metodológica para el caso de la empresa . . . 18

7. Metodología **21**
7.1. Fase 1: Comprensión del negocio . . . 21
7.2. Fase 2: Comprensión de los datos . . . 21
7.3. Fase 3: Preparación de los datos . . . 22

7.4. Fase 4: Modelado 22
7.5. Fase 5: Evaluación 23
7.6. Fase 6: Despliegue y políticas de negocio 23

8. Desarrollo y Resultados **24**
8.1. Fase 1: Comprensión del negocio 24
8.1.1. Contexto de Reservo y modelo de suscripción 24
8.1.2. Problema de gestión asociado a la baja de clientes 24
8.1.3. Definición del objetivo general y de los objetivos específicos 24
8.1.4. Indicadores de éxito y definición de entregables 24
8.1.5. Línea base económica y evaluación preliminar 25
8.2. Fase 2: Comprensión de los datos 26
8.2.1. Inventario de fuentes y tablas principales 26
8.2.2. Estructura y calidad de las tablas 27
8.2.3. Calendario de cortes mensuales 27
8.2.4. Definiciones operativas de estados de cliente 28
8.3. Fase 3: Preparación de los datos 28
8.3.1. Diseño de la estructura del datamart mensual 28
8.3.2. Construcción de variables de contexto, valor, uso y fricción 29
8.3.3. Definición de la etiqueta de baja a horizonte mensual 31
8.3.4. Tratamiento de valores faltantes y valores extremos 31
8.4. Fase 4: Modelado 33
8.4.1. Selección del algoritmo y definición del problema de clasificación . . 33
8.4.2. Partición temporal y tamaño muestral para entrenamiento y calibración 33
8.4.3. Implementación del flujo de preprocesamiento y del pipeline de modelado 34
8.4.4. Entrenamiento, calibración y elección del modelo final 35
8.5. Fase 5: Evaluación 36
8.5.1. Desempeño global en el conjunto de prueba 36
8.5.2. Calibración de probabilidades y estabilidad por segmentos 36
8.5.3. Pruebas de robustez por país y rubro 37
8.5.4. Conclusiones sobre suficiencia del modelo para uso operativo 38
8.6. Fase 6: Despliegue y políticas de negocio 38
8.6.1. Flujo mensual de scoring sobre la cartera actualizada 38
8.6.2. Artefactos operativos y carpeta de uso para Customer Success . . . 39
8.6.3. Segmentación conductual y políticas preliminares 39
8.6.4. Material de apoyo, pruebas en vivo y adopción del prototipo 41

9. Discusiones **42**
9.1. Decisiones de diseño del modelo 42
9.2. Impacto esperado en la operación y rol de Customer Success 42
9.3. Comportamiento del cliente y límites del modelo 43

9.4. Limitaciones de datos y riesgos en el uso del prototipo 44

10. Conclusiones **45**
10.1. Cumplimiento de los objetivos e indicadores 45
10.2. Conclusiones generales 46

Referencias **48**

Anexo A. Organigrama **50**

Anexo B. Estados del cliente **50**
B.1. 51
B.2. 52
B.3. 53
B.4. 54
B.5. 55

Anexo C. Indicadores del proceso **57**

Anexo D. Tablas de Desarrollo **58**
D.1. 58
D.2. 58
D.3. 59
D.4. 59
D.5. 60
D.6. 60

Índice de Figuras

1. Flujo General del Cliente por Área. Fuente: elaboración propia 4
2. Churn 3 años (ene-2023 a jul-2025) y tendencia. Fuente: elaboración propia . 7
3. Número de clientes al inicio de cada mes (ene-2023 a jul-2025). Fuente: elaboración propia 7
A.1. Organigrama de Reservo, Agosto 2025. Fuente: elaboración propia 50
B.1. Etapa de Adquisición en Reservo. Fuente: elaboración propia 51
B.2. Etapa de Venta en Reservo. Fuente: elaboración propia 52
B.3. Etapa de Onboarding del cliente en Reservo. Fuente: elaboración propia . . . 53
B.4. Etapa de cliente activo en Reservo. Fuente: elaboración propia 54
B.5. Etapa de Cliente inactivo en Reservo. Fuente: elaboración propia 55
B.6. Proceso completo de cliente en Reservo. Fuente: elaboración propia 56
D.1. Porcentaje de nulos por variable. Fuente: elaboración propia 59
D.2. Tipos de datos de las variables. Fuente: elaboración propia 60
D.3. Estadísticas descriptivas de variables numéricas. Fuente: elaboración propia . 60

Índice de Tablas

C.1. Métricas asociadas a clientes. Fuente: Elaboración propia 57
D.1. Bloqueados y actividad de citas por rubro. Fuente: elaboración propia 58
D.2. Bloqueados y actividad de citas por plan. Fuente: elaboración propia 58
D.3. Promedio de mensualidad por rubro (CLP). Fuente: elaboración propia 59

1. Antecedentes generales

1.1. Industria y ambiente competitivo

El sector de la salud en Chile y en América Latina atraviesa un proceso de transformación digital sostenido. En 2024, la CEPAL lanzó el Observatorio de Desarrollo Digital, que reúne más de 100 indicadores organizados en 12 áreas y permite dimensionar las principales brechas. Los datos muestran que una mayoría de las empresas que utilizan Internet mantiene solo una presencia pasiva y que una proporción muy alta de las MIPYMES ni siquiera cuenta con presencia en línea, lo que refuerza la urgencia de digitalizar procesos de salud y servicios relacionados (CEPAL, 2024). En paralelo, el ecosistema regional de innovación en salud ya identifica un universo superior al millar de empresas y startups, con una concentración importante en soluciones de prevención y en sistemas de soporte, de acuerdo con el reporte conjunto IDB Lab–HolonIQ (IDB Lab and HolonIQ, 2024).

En Chile, este dinamismo se refleja en Start-Up Chile: la cohorte BIG 4 incorporó decenas de nuevas startups, con una fracción relevante en el ámbito Health & Biotech, y moviliza recursos por varios miles de millones de pesos chilenos en apoyos directos. Desde 2010 la aceleradora ha respaldado más de 2,200 startups, cuyo portafolio alcanza una valoración de varios miles de millones de dólares y ventas acumuladas del mismo orden de magnitud (Paredes, 2025). En coherencia con esta tendencia, el flujo de capital de riesgo hacia *healthtech* en América Latina pasó de montos relativamente acotados en 2019 a superar el umbral de los mil millones de dólares en 2021 (Munar, 2023). En este contexto, y siguiendo la *Classification of Digital Health Interventions* de la OMS, la salud digital comprende intervenciones dirigidas a clientes, proveedores y gestores del sistema, que abarcan desde teleconsulta y autogestión hasta analítica y soporte a la toma de decisiones, delimitando así el alcance de las soluciones consideradas en esta memoria (World Health Organization, 2018).

La principal fuerza que explica este cambio en Latinoamérica y en Chile fue la aceleración digital asociada a la pandemia, que expandió rápidamente la telemedicina y sentó las bases de un modelo híbrido de atención (Superintendencia de Salud de Chile, 2025). En la etapa posterior al COVID-19 se redefinieron las expectativas: pacientes y equipos de salud valoran la continuidad de cuidados, el acceso a especialistas a distancia y una mejor coordinación entre niveles. Al mismo tiempo, persisten asimetrías de recursos y brechas de adopción que limitan el uso sostenido de estas soluciones (Revista Chilena de Salud Pública (Universidad de Chile), 2025).

Este entorno de alta demanda ha generado un ecosistema de proveedores de software competitivo y diverso. Se pueden identificar tres perfiles principales de actores en el mercado:

- Startups y empresas nativas digitales. Son compañías ágiles, especializadas en nichos específicos y con alta capacidad de innovación. Sin embargo, suelen enfrentar desafíos para escalar y para consolidar la confianza del mercado.

- Empresas locales consolidadas. Poseen un conocimiento profundo del mercado chileno, incluyendo sus complejidades regulatorias y culturales. Suelen contar con una base de clientes estable, aunque pueden avanzar con mayor lentitud en la adopción de nuevas

tecnologías.

- Actores internacionales. Cuentan con grandes recursos, tecnología avanzada y marcas reconocidas globalmente. Su principal desafío es adaptar sus soluciones estandarizadas a las particularidades del sistema de salud y a las normativas chilenas, como la Ley de Derechos y Deberes del Paciente (Biblioteca del Congreso Nacional de Chile, 2012), que establece requisitos estrictos sobre la seguridad y privacidad de la ficha clínica.

En Chile, el universo direccionable para Reservo combina prestadores individuales habilitados y prestadores institucionales ambulatorios. A marzo de 2024, el Registro de la Superintendencia de Salud contabiliza 433.431 profesionales de la salud certificados, principalmente psicólogos, enfermeros y médicos, que constituyen la base de potenciales cuentas individuales y consultas privadas (Clínicas de Chile A.G., 2025). En el segmento institucional privado, a febrero de 2025 existían 555 prestadores privados acreditados, de los cuales 175 corresponden a *atención abierta* (centros ambulatorios), el subsegmento con demanda directa por agendamiento, recordatorios y gestión de pacientes (Superintendencia de Salud (Gobierno de Chile), 2025).

El espacio competitivo local y regional muestra una escala ya consolidada. AgendaPro reporta una base de más de 100.000 profesionales y decenas de miles de negocios gestionados, con más de 100 millones de citas procesadas (AgendaPro, 2025). Medilink (Healthatom) informa miles de clientes y decenas de millones de citas efectivas acumuladas (Healthatom (Medilink), 2025). Encuadrado, enfocada en profesionales independientes de la salud, señala que en 2025 trabaja con cientos de centros y con una base superior a 5.000 profesionales activos (Encuadrado, 2025).

1.2. Características de la empresa u organización

RESERVO es una empresa chilena de tecnología SaaS cuyo rol en la industria es actuar como socio tecnológico integral para profesionales y centros de salud de tamaño pequeño y mediano (RESERVO, 2025). Su modelo de negocio se centra en un nicho de mercado que históricamente ha sido desatendido por las grandes corporaciones de software, las cuales se enfocan en hospitales y grandes cadenas de clínicas. RESERVO atiende específicamente a especialistas independientes, dentistas, kinesiólogos, psicólogos y clínicas medianas, describiendo así las características de la organización. La base actual de clientes se concentra principalmente en Chile, Argentina, Colombia y México, lo que refuerza su posicionamiento en el segmento latinoamericano de salud ambulatoria.

RESERVO ofrece planes escalonados (Individual, Básico, Reservo y Enterprise) que se diferencian por alcance funcional, cantidad de usuarios y nivel de soporte, cubriendo desde profesionales independientes hasta centros multiusuario y multisucursal. En términos generales, todos los planes incluyen agenda y reservas en línea con recordatorios, ficha clínica electrónica, reportes y un módulo financiero. Los planes superiores agregan control de permisos, automatizaciones, centros y usuarios ilimitados, además de soporte prioritario. La plataforma dispone de integraciones con medios de pago en línea y POS, emisión de documentos tributarios, conectores de marketing y redes sociales, comercio electrónico, receta

electrónica y servicios de exámenes a domicilio, además de integraciones contables y financieras. Como extras se consideran, entre otros, consentimiento informado con firma electrónica, ampliación de cupos de comunicaciones, dominios o sitio web y habilitación de conectores avanzados según la necesidad de cada centro.

La oportunidad que la empresa busca abordar se basa en un problema claro que enfrentan sus potenciales clientes: estos profesionales a menudo invierten una cantidad desproporcionada de su tiempo en tareas administrativas (gestión de agendas, recordatorios de citas, cobros) en lugar de dedicar ese tiempo a la atención directa de pacientes. Además, muchos carecen de las herramientas y del conocimiento para competir digitalmente y atraer nuevos pacientes, lo que representa una oportunidad de mejora[1].

Para resolver estos problemas, el producto principal de RESERVO es una plataforma centralizada y modular que ofrece una solución completa[2]:

- Eficiencia operativa. Automatiza la gestión de la agenda, el envío de recordatorios por WhatsApp y correo electrónico, y centraliza las fichas clínicas de los pacientes en un solo lugar.
- Gestión financiera. Simplifica la emisión de boletas y el control de ingresos, proporcionando reportes que facilitan la toma de decisiones.
- Marketing y presencia digital. Ofrece herramientas para la creación de un sitio web profesional con un sistema de reservas en línea integrado, permitiendo a los profesionales captar pacientes durante todo el día.

Este enfoque no solo entrega un software, sino que ofrece una solución accesible y escalable que se adapta a las necesidades particulares de sus usuarios. De esta forma, RESERVO se posiciona como un catalizador que permite a sus clientes optimizar su eficiencia, aumentar su rentabilidad y consolidar su presencia digital en un mercado altamente competitivo, definiendo así su rol dentro de la industria.

La estructura organizacional de la empresa, detallada en el Organigrama General anexo A.1, se organiza de manera jerárquica y funcional bajo la dirección del CEO de la compañía. Reportan directamente a esta jefatura cinco gerencias o liderazgos que agrupan las áreas clave de la organización: Post-venta, Customer Success, Comercial, Marketing y Desarrollo, cada una con un responsable a cargo del equipo correspondiente.

Cada líder supervisa a sus respectivos equipos operativos. El área de Desarrollo es la de mayor tamaño, con un equipo de 11 trabajadores, seguida por el área Comercial con 8 trabajadores. El equipo de Customer Success está compuesto por 5 personas y el de Marketing por 2 personas. El departamento de Post-venta presenta una subestructura en la que una jefatura de soporte lidera un equipo de 5 trabajadores, manteniendo la coordinación con la gerencia del área.

[1] Análisis basado en una entrevista con la Customer Success Manager de RESERVO, realizada el 15 de agosto de 2025.

[2] Descripción de funcionalidades basada en la información pública disponible en la sección Çaracterísticas"del sitio web oficial de RESERVO. https://www.reservo.cl/caracteristicas

2. Descripción del problema u oportunidad

2.1. Antecedentes

2.1.1. Proceso general

La Figura 1 muestra un diagrama del flujo general que sigue un cliente a lo largo de su ciclo de vida dentro de Reservo, visto desde la perspectiva de las áreas funcionales involucradas. El recorrido inicia con el primer contacto a través de Marketing, continúa con el proceso de calificación y venta por parte de los equipos SDR y Ejecutivos, y sigue con la etapa de incorporación (Onboarding) gestionada por Customer Success. Finalmente, el cliente interactúa con Soporte y entra en un ciclo de Retención, que culmina con su continuidad o su eventual pérdida (churn)

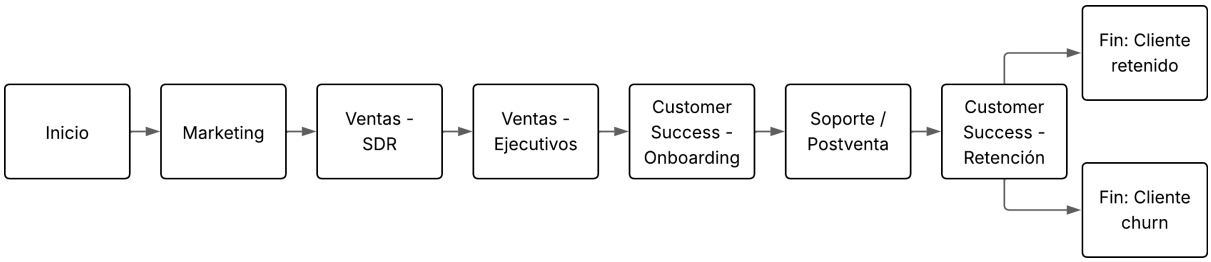

Figura 1: Flujo General del Cliente por Área. Fuente: elaboración propia

2.1.2. Etapa de Captación

El proceso de captación, ilustrado en el anexo B.1, es iniciado por el área de **Marketing**, que ejecuta una acción específica para atraer el interés de potenciales clientes. Un **cliente** potencial encuentra esta acción de marketing y procede a registrar su información en la plataforma de Reservo. Este registro representa la primera transición crucial, cambiando el estado del **cliente** de un anónimo **'Desconocido'** a un **'Lead'** conocido dentro del sistema de Reservo.

Una vez enviados los datos, estos son recibidos por el equipo de **Ventas SDR** (Sales Development Representative), que realiza la tarea inicial de configurar el lead para su posterior contacto. El **SDR** procede a contactar al prospecto; en este punto, el flujo depende de la respuesta del **cliente**, ya que el proceso solo continúa si este contesta y acepta seguir adelante. Tras una interacción exitosa, el **SDR** ejecuta la tarea de 'Calificar Lead' para determinar si el prospecto encaja con el perfil de cliente ideal de la empresa. Si la calificación es positiva, el **cliente** experimenta su segundo cambio de estado importante, convirtiéndose en un **'Lead calificado'**.

Para concluir esta fase, el equipo **SDR** se encarga de agendar una demostración con un **ejecutivo de ventas** y de enviar una cotización formal. La programación exitosa de esta demo marca la tercera y última transición de estado en este diagrama, elevando al prospecto a una **'Oportunidad de Venta'**. Con esto finaliza oficialmente el proceso de captación inicial y se transfiere al **cliente** a la siguiente etapa del embudo de ventas.

2.1.3. Etapa de Ventas

El proceso de Venta, detallado en el anexo B.2, comienza cuando un **cliente** en estado de 'Oportunidad de Venta' asiste a una demostración del producto. Una vez finalizada la demo, si el **cliente** decide contratar el servicio, el **Ejecutivo de Venta** procede a configurar al prospecto en el sistema, momento en el cual se produce la primera transición de estado importante, actualizando su condición a **'Precliente'**. A continuación, el **Ejecutivo de Venta** envía las instrucciones de pago y, una vez que el **cliente** completa dicha transacción, se realiza el cambio de estado final: el prospecto es convertido oficialmente en un **'Cliente'**. Finalmente, el **Ejecutivo de Venta** transfiere al nuevo **cliente** al área de **Customer Success**, dando inicio al 'Proceso de Onboarding' y concluyendo así la etapa comercial.

2.1.4. Etapa de Onboarding

El proceso de Onboarding, como se detalla en el anexo B.3, comienza inmediatamente después de que finaliza la venta, con el equipo de **Customer Success** preparando la cuenta e invitando al nuevo **cliente** a una primera capacitación. Una vez realizada esta sesión inicial, inicia una fase de seguimiento para monitorear si el **cliente** utiliza activamente la plataforma. Durante este período, ocurren las transiciones más relevantes, ya que, basándose en el nivel de riesgo detectado, un **cliente** puede ser clasificado como de **'riesgo alto'** o **'riesgo medio'**. Esta clasificación desencadena acciones de contacto proactivo por parte del equipo de **Customer Success**. Si el **cliente** no presenta riesgos y transcurre un período determinado, el proceso de Onboarding se da por finalizado, marcando la transición del **cliente** a un estado de uso regular de la herramienta.

2.1.5. Etapa de Cliente Activo

La etapa de **'Cliente Activo'**, ilustrada en el anexo B.4, representa el ciclo de vida del **cliente** una vez finalizado el proceso de Onboarding, centrándose en la retención y expansión. En esta fase, el equipo de **Customer Success** realiza un monitoreo constante de la salud de la cuenta. Si se detecta un uso deficiente, se activan acciones de seguimiento, lo que implícitamente clasifica al **cliente** como un perfil **'en riesgo'** para mitigar una posible baja. Por el contrario, si la salud de la cuenta es buena, el equipo busca oportunidades de expansión (upselling); si el **cliente** acepta y completa el pago, su condición se actualiza, reafirmándolo como un **'cliente vigente'**. Paralelamente, el proceso gestiona las interacciones del **cliente** con el área de **Soporte** y los ciclos de facturación, donde un fallo recurrente en el pago puede culminar con la **pérdida del cliente (churn)**.

2.1.6. Etapa de Cliente Inactivo

El proceso de **'Cliente Inactivo'**, detallado en el anexo B.5, gestiona tanto la baja de un **cliente** como su posible reactivación. El flujo se inicia cuando un **cliente** solicita cancelar su servicio, ya sea durante el Onboarding o en su ciclo de vida activo. El equipo de **Customer Success** procesa esta solicitud, formalizando la transición del **cliente** a un estado **'dado de baja'**. Posteriormente, se registran las razones de la pérdida y se informa al **cliente** para cerrar el ciclo. El diagrama también contempla un camino para la recuperación; si un

cliente inactivo decide volver a contratar, el equipo de **Customer Success** gestiona el nuevo contrato y la reactivación de la cuenta. Esta acción revierte el estado del **cliente**, devolviéndolo a la condición de **'cliente activo'** y reintegrándolo al ciclo de vida principal.

2.2. Problema encontrado

Para asegurar su crecimiento en el competitivo mercado SaaS, Reservo debe optimizar continuamente el valor que extrae de su base de clientes. Actualmente, la organización enfrenta desafíos que limitan su capacidad para retener y expandir cuentas de manera eficiente. Estos desafíos se manifiestan en una serie de efectos observables que impactan directamente la rentabilidad y la sostenibilidad del negocio.

2.2.1. Efectos y consecuencias observadas

Los resultados de la gestión actual del ciclo de vida del cliente presentan tres consecuencias principales:

- **Pérdida recurrente de clientes e ingresos:** La empresa experimenta una **Tasa de Churn** mensual de **2,46 %**, lo que se ha traducido en **70 bajas** en lo que va de 2025[3]. Desde enero de 2022, el churn mensual promedia **2,77 %**; aunque la serie exhibe una *tendencia* decreciente, el comportamiento histórico y reciente se aprecia en la Figura 2, junto a la que se encuentra la evolución de número de clientes por cada mes (Figura 3)

  No obstante, el indicador acumula aproximadamente **dos años sin perforar el 2 %**, evidenciando un **estancamiento** en el rango 2–3 %. Esto es relevante porque los principales *benchmarks* para empresas de suscripción (SaaS) recomiendan apuntar a **menos de 2 % de churn mensual** para situarse entre las mejores prácticas del mercado (Jain, 2023). Mientras el churn permanezca por encima de ese umbral, la fuga de clientes seguirá impactando los ingresos recurrentes y condicionando el crecimiento neto.

- **Expansión y reactivación no sistemáticas:** Aunque la empresa logra generar valor adicional, los resultados no muestran un crecimiento acelerado. Durante 2024 se lograron **57 upsellings**, mientras que en 2025 se han conseguido **60** hasta la fecha. En cuanto a la reactivación, en 2024 se recuperaron **100 clientes**, mientras que en 2025 van **89**[4]. Estas cifras sugieren un crecimiento modesto en la expansión y una posible disminución en la capacidad de reactivar cuentas, indicando la falta de una estrategia proactiva y sistemática.

- **Asignación ineficiente de recursos de postventa:** Los esfuerzos de Customer Success exhiben *baja efectividad* porque se interviene tarde y con ofertas poco ajustadas al perfil y necesidades del cliente en riesgo. No existe una clasificación operativa de riesgo durante el ciclo activo (más allá del onboarding), por lo que las acciones se activan

[3] La **Tasa de Churn** se define en la tabla C.1. El valor y el número de bajas corresponden a los datos internos de la empresa para el año 2025. Fuente: Base de datos de Reservo.

[4] Los datos de upsellings y clientes reactivados corresponden a los registros internos de la empresa. Fuente: Base de datos de Reservo.

cuando la probabilidad de abandono ya es alta; así, se prioriza reactivamente a clientes al borde del churn y se desaprovechan intervenciones tempranas con mayor probabilidad de retención y/o expansión.

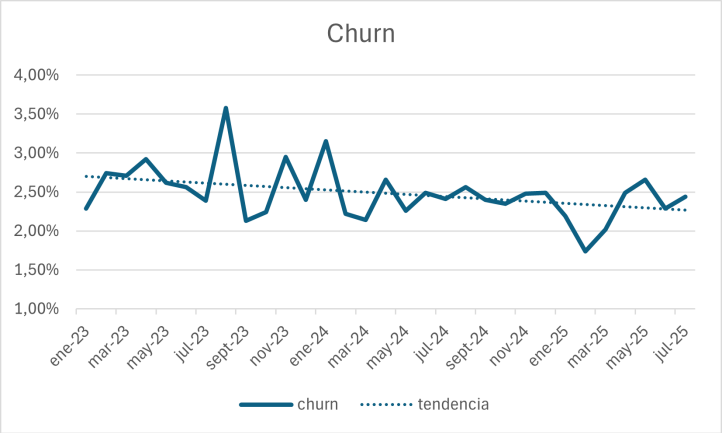

Figura 2: Churn 3 años (ene-2023 a jul-2025) y tendencia. Fuente: elaboración propia

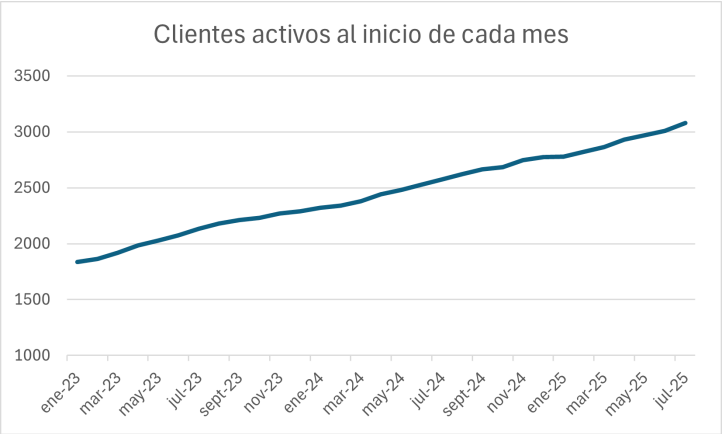

Figura 3: Número de clientes al inicio de cada mes (ene-2023 a jul-2025). Fuente: elaboración propia

2.2.2. Análisis y Elección del Problema Central

Los efectos descritos (pérdida de clientes, expansión no optimizada e ineficiencia) son síntomas de varios problemas subyacentes. Para seleccionar el problema central, se utiliza como base teórica el marco de **Gestión del Ciclo de Vida del Cliente (Customer Lifecycle Management)**, que postula que las acciones de una empresa deben adaptarse a la etapa y al comportamiento específico de cada cliente para ser efectivas.

Bajo esta óptica, la elevada tasa de abandono y el bajo crecimiento del valor no son problemas raíz, sino consecuencias directas de un problema más profundo y operativo. Se

elige como problema central aquel que, de ser solucionado, tendría el mayor impacto en mitigar los demás. Por lo tanto, se descartan los síntomas y se selecciona la causa operativa fundamental que los origina. El problema central es:

Insuficiente caracterización y segmentación conductual de la cartera activa en postventa

2.2.3. Causas del Problema Central

Este problema no se debe a una falta de datos, sino a la forma en que la empresa los interpreta y los utiliza para guiar sus acciones. Las causas fundamentales son:

- **Toma de decisiones basada en indicadores de resultado:** Las estrategias se activan a partir de métricas retrospectivas, como la **'Tasa de Churn'** o un **'NPS'** de **52**[5]. Estos indicadores miden un resultado que ya ocurrió, pero no permiten diferenciar el tratamiento entre clientes *antes* de que el riesgo se materialice.
- **Análisis estático de la información:** La empresa analiza datos de manera estática, observando el estado actual de un cliente, pero no su evolución en el tiempo. Se carece de una visión longitudinal del comportamiento, lo que impide identificar tendencias, como una disminución gradual del uso de la plataforma, que son señales tempranas de un posible abandono.
- **Ausencia de criterios conductuales para la segmentación:** No se ha definido formalmente qué patrones de uso se correlacionan con un cliente saludable, en riesgo o con potencial de expansión. Sin estos criterios, es imposible segmentar la cartera de manera dinámica para aplicar acciones diferenciadas.
- **Enfoque operativo centrado en la reacción a eventos:** El flujo de trabajo del equipo de Customer Success está estructurado para reaccionar a eventos negativos (quejas, impagos) en lugar de estar diseñado para segmentar proactivamente la base de clientes y ejecutar acciones personalizadas.

[5] El **NPS** se define en la tabla C.1. El valor de 52 es el último resultado medido por la empresa. Fuente: Base de datos de Reservo.

3. Descripción y Justificación del Proyecto

La sección anterior definió como problema central la insuficiente caracterización y segmentación conductual de la cartera activa en postventa. A continuación, se presenta un proyecto diseñado para abordar directamente las causas de este problema, sentando las bases para una gestión del cliente más estratégica y proactiva, basada en evidencia teórica y en buenas prácticas de gestión.

El proyecto se titula "Diseño de políticas comerciales para una empresa de tecnología para servicios de salud basado en el comportamiento de sus clientes".

3.1. Definición y resultado del proyecto

El proyecto consiste en el diseño de un modelo analítico y de un conjunto de herramientas que permiten apoyar la gestión comercial de la cartera de clientes de Reservo. El foco está en reducir la baja de clientes y en aprovechar mejor las oportunidades de expansión comercial, tanto en la etapa de onboarding como una vez que el cliente ya se encuentra en la fase de uso normal del servicio.

El eje central del proyecto es un modelo que estima, para cada cliente, la probabilidad de que deje de usar la plataforma. Este cálculo se realiza de manera recurrente a partir de la información histórica de comportamiento y de facturación. De este modo, la empresa puede contar con una señal temprana de riesgo desde el momento en que el cliente inicia su relación con la plataforma y durante toda su vida activa.

Sobre la base de estas probabilidades se construyen listados y segmentaciones de la cartera. Estos listados permiten identificar a los clientes con mayor probabilidad de abandono, priorizar los esfuerzos de retención y apoyar decisiones de expansión comercial en los grupos con mayor potencial. El resultado es una gestión apoyada en analítica, donde los recursos del equipo se orientan primero hacia los clientes con mayor impacto esperado en ingresos futuros.

Para hacer operable este enfoque, el proyecto entrega varios artefactos concretos. En primer lugar, se construye un datamart que reúne y organiza la información relevante de clientes y uso del sistema. En segundo lugar, se entrena y documenta el modelo de riesgo de baja. En tercer lugar, se implementa un flujo simple de uso en un notebook de Google Colab y en archivos de Excel, que permite al equipo de Customer Success aplicar el modelo sobre bases mensuales actualizadas sin necesidad de conocimientos avanzados de programación.

El resultado final es un puente entre la capa analítica y la operación diaria. Cada ciclo de uso del modelo genera archivos con la lista de clientes, su nivel de riesgo y la información necesaria para planificar acciones. A partir de estos insumos se definen políticas comerciales prácticas, entendidas como reglas y recomendaciones de acción diferenciadas por tipo de cliente y nivel de riesgo. De esta forma, el proyecto no solo describe un modelo, sino que entrega una forma concreta de usarlo en la gestión cotidiana de la empresa.

3.2. Justificación estratégica

La realización de este proyecto se justifica por su alineación directa con la necesidad de la empresa de optimizar la rentabilidad de su cartera y asegurar un crecimiento sostenible. La gestión proactiva del cliente basada en datos es un elemento clave para la competitividad y la rentabilidad en mercados digitales (Kumar and Reinartz, 2018).

Las razones estratégicas se basan en tres pilares principales:

- Mitigar la pérdida de ingresos por bajas de clientes. La tasa mensual de bajas se estima en torno a 2,46 % y afecta de manera directa los ingresos recurrentes. La evolución histórica se muestra en la Figura 2. Un modelo predictivo permite anticipar señales de deserción y entregar al equipo comercial una lista de clientes con mayor riesgo, de modo que se puedan activar acciones de retención más oportunas, en línea con la literatura de ciclo de vida del cliente (Lemmens and Croux, 2008).

- Capitalizar oportunidades de expansión. Aumentar el valor económico de cada cliente mediante ventas adicionales y aumento de plan permite aprovechar mejor la base instalada (Kumar and Reinartz, 2018). La evolución observada en los indicadores internos (57 en 2024 frente a 60 en 2025) sugiere que existe espacio para sistematizar estas oportunidades y convertirlas en una fuente más estable de crecimiento.

- Optimizar el esfuerzo de Customer Success. Un trato homogéneo de toda la cartera genera sobrecostos y baja efectividad. La segmentación basada en datos permite distinguir clientes de mayor riesgo o mayor potencial y asignar prioridades claras de trabajo. Esto facilita organizar la agenda del equipo, concentrar los esfuerzos donde el impacto esperado es mayor y se alinea con prácticas de gestión de relaciones con clientes (Kumar and Reinartz, 2018).

3.3. Evaluación económica

La cartera actual de Reservo está compuesta por cerca de 3.500 clientes activos distribuidos en cuatro planes de suscripción mensual, con valores que van desde $30.000 hasta $150.000 por cliente. Con esta estructura de precios, el ingreso mensual por suscripciones se sitúa en torno a $205.450.000 y el ingreso anual aproximado alcanza los $2.465.400.000 pesos chilenos, según la base de datos utilizada en esta memoria. Esto implica un pago promedio cercano a $58.700 mensuales por cliente.

La tasa de bajas mensuales se estima en torno a 2,4 %. Con este nivel, la empresa pierde alrededor de 80 clientes al mes, lo que equivale a cerca de 1.000 clientes en un año. En términos de ingresos, esta dinámica se traduce en una pérdida anual cercana a $59.000.000 de pesos en suscripciones que dejan de cobrarse. Cada décima de punto porcentual de reducción en la tasa de bajas, es decir 0,1 puntos, representa del orden de $2.500.000 de pesos anuales en ingresos conservados. Esta cifra entrega una referencia directa sobre cuánto vale económicamente mejorar la retención.

El proyecto busca reducir estas pérdidas mediante un uso más focalizado de los recursos comerciales. El modelo permite ordenar la cartera según probabilidad de baja y entregar al

equipo de Customer Success un listado de clientes priorizados. Así se facilita concentrar los esfuerzos en quienes generan mayor riesgo económico. Si el uso del modelo y de las políticas asociadas permitiera reducir la tasa mensual desde 2,4 % a 2,0 %, la empresa dejaría de perder cerca de $10.000.000 de pesos al año en ingresos por suscripciones, solo por efecto de una menor cantidad de clientes que se dan de baja.

La segmentación por comportamiento también abre espacio para acciones de expansión comercial. Un subconjunto de clientes puede estar en condiciones de aumentar de plan o contratar servicios adicionales. Si una fracción pequeña de la cartera incrementa su pago mensual, el ingreso adicional anual puede ser comparable al monto ahorrado por una mejor retención, lo que refuerza el impacto económico combinado de ambas palancas.

Los detalles de las métricas, las fórmulas y los supuestos que permiten cuantificar el valor económico por cliente y proyectar escenarios más completos de ingresos se desarrollan en el marco conceptual y en el capítulo metodológico, siguiendo la literatura de analítica de clientes y gestión basada en valor (Chapman et al., 2000, Gupta et al., 2004, Kumar and Reinartz, 2018).

3.4. Razones prácticas y técnicas

El enfoque elegido se apoya en las capacidades y recursos que ya existen en Reservo. La empresa cuenta con bases de datos históricas de uso de la plataforma, estados de cliente, planes, facturación y tickets de soporte, además de una infraestructura básica para analítica y herramientas de BI. Sobre esta base es posible construir un flujo reproducible que incluye extracción de datos, depuración, construcción de un datamart, segmentación de clientes y definición de reglas de acción conectadas con la operación diaria.

La segmentación conductual permite definir riesgos y oportunidades a partir de variables observables y actualizables en el tiempo, como patrones de uso y comportamiento de pago. Los modelos utilizados privilegian interpretabilidad, trazabilidad y control de supuestos, de modo que sus resultados puedan ser revisados y entendidos por los equipos de negocio. Esto facilita que el modelo no sea una caja negra, sino una herramienta de apoyo a la decisión integrada al lenguaje cotidiano de la empresa.

A lo largo del desarrollo del proyecto se prepara material práctico para el uso del modelo. El estudiante deja al equipo una carpeta estructurada con los scripts de generación del datamart, el notebook de scoring en Google Colab y los archivos de Excel que presentan los resultados en formatos conocidos para Customer Success. Esta carpeta se complementa con tutoriales escritos y sesiones de capacitación realizadas con el equipo, aprovechando su experiencia previa en el uso de hojas de cálculo y paneles de BI. El resultado esperado es un diseño validado en datos históricos y un conjunto de políticas comerciales que el equipo puede aplicar de manera autónoma, en línea con la gestión de clientes basada en valor y con el uso de analítica para priorizar esfuerzos de retención y expansión (Kumar and Reinartz, 2018).

3.5. Elección del enfoque

Se elige un modelo analítico de segmentación conductual con scoring y reglas de acción. La motivación principal es que permite identificar grupos de clientes según su comportamiento y asignar a cada grupo un nivel de prioridad comercial concreto. Esto facilita orientar los esfuerzos del equipo hacia quienes presentan mayor probabilidad de baja o mayor potencial de crecimiento, utilizando la información disponible en la base de datos de la empresa.

Frente a alternativas centradas solo en reportes descriptivos, este enfoque agrega una capa de predicción y ordenamiento que entrega listas accionables. Frente a reglas puramente heurísticas, aporta criterios construidos a partir de datos históricos y actualizables en el tiempo. Al mismo tiempo, mantiene una estructura sencilla: variables comprensibles para el negocio, reglas claras de interpretación y resultados que se pueden revisar en herramientas habituales como hojas de cálculo. De este modo, el enfoque combina impacto esperado en retención y expansión, interpretabilidad para los equipos comerciales y compatibilidad con la infraestructura actual, en línea con la literatura de CRM y gestión del ciclo de vida del cliente (Kumar and Reinartz, 2018).

4. Alcance

El alcance del proyecto se define desde la primera facturación del cliente y su incorporación a la plataforma hasta su estado de uso activo. El modelo y las políticas se aplican a clientes que se encuentran en proceso de onboarding o en estado activo, utilizando como referencia el comportamiento histórico registrado en las bases de datos. Como parte del alcance, el estudiante entrega un prototipo analítico, una carpeta de uso con los scripts de generación del datamart, el notebook de scoring en Google Colab y los archivos de Excel. Este material se complementa con tutoriales escritos y sesiones de traspaso de conocimiento para el equipo de Customer Success y Post-venta, de modo que estos puedan continuar la operación y avanzar en la futura implementación del modelo.

Quedan fuera del alcance del proyecto los clientes que ya se encuentran dados de baja, quienes se utilizan solo como historial para el entrenamiento del modelo y para mediciones agregadas, pero no son objeto de políticas directas. También quedan fuera los potenciales clientes o leads en las etapas de captación y venta, la implementación productiva completa en los sistemas de la empresa, la automatización en tiempo real, la orquestación de procesos y las integraciones con herramientas externas. No se abordan el diseño y la ejecución de campañas de marketing, la compra de medios ni las automatizaciones de comunicación asociadas, ni tampoco cambios de precios, diseño de nuevos planes comerciales o definición de políticas de descuento. Los procesos de facturación, cobranza y medios de pago solo se consideran como fuente de información para el análisis, sin rediseñar su operación.

Tampoco forman parte del alcance la definición formal de gobierno de datos, seguridad y cumplimiento regulatorio más allá de lo necesario para realizar el proyecto con datos internos. No se desarrollan experimentos a gran escala, como pruebas A/B, modelos causales de impacto o esquemas de atribución multicanal, ni nuevas interfaces de usuario para la explotación en tiempo real del modelo. La capacitación se limita a las sesiones de traspaso realizadas con el equipo de Customer Success y Post-venta, sin programas de formación extensiva ni certificaciones internas. El uso operativo del modelo se restringe a estos equipos y no se considera su adopción por otras áreas de la empresa en esta etapa.

5. Objetivos del proyecto

5.1. Objetivo general

Desarrollar un modelo analítico de segmentación conductual para la cartera de clientes de Reservo, que permita diferenciar y gestionar de manera proactiva las estrategias de retención y expansión para cada tipo de cliente.

5.2. Objetivos específicos

Para alcanzar el objetivo general, se deben generar los siguientes resultados específicos, cada uno de los cuales aborda una de las causas del problema central:

- Obtener un conjunto validado de variables de comportamiento que caractericen a los clientes y permitan predecir el riesgo de abandono y las oportunidades de expansión.
- Construir un repositorio estructurado de datos (datamart) que consolide la información de clientes y habilite el análisis de comportamiento y el desarrollo de modelos predictivos.
- Definir segmentos de clientes definidos y caracterizados en función de sus patrones de comportamiento dinámicos y su evolución en el tiempo.
- Diseñar un portafolio de políticas de negocio personalizadas para cada segmento identificado, orientadas a guiar las acciones del equipo de Customer Success.
- Implementar un prototipo operativo del modelo analítico y del portafolio de políticas en la empresa, con criterios de éxito y lineamientos de adopción.

5.3. Indicadores de éxito

- Para el objetivo de definir el conjunto de variables de comportamiento, se usará como indicador la capacidad del modelo para distinguir entre clientes que se dan de baja y clientes que se mantienen. Esta capacidad se medirá con la métrica AUC y se considerará aceptable un valor igual o superior a 0,70 en un periodo de prueba independiente (Hosmer et al., 2013).
- Para el objetivo de construir el datamart de clientes, el indicador será la cobertura de la cartera activa. En cada corte mensual se espera que al menos un 90 % de los clientes activos tenga disponibles todas las variables necesarias para aplicar el modelo y generar segmentaciones (Kumar and Reinartz, 2018).
- Para el objetivo de definir y caracterizar segmentos según comportamiento, se evaluará la capacidad de priorización del modelo. Se espera que el 20 % de los clientes con mayor riesgo estimado concentre al menos un 40 % de las bajas observadas en el periodo de prueba, lo que muestra que el ranking permite focalizar acciones en un grupo reducido con alto impacto (Inc., 2021).

- Para el objetivo de diseñar un portafolio de políticas comerciales, el indicador será la existencia de una matriz que relacione cada segmento con acciones concretas para Customer Success y Post-venta. Esta matriz debe cubrir al menos un 80 % de la cartera activa y haber sido revisada y validada en sesiones de trabajo con los equipos involucrados (Kumar and Reinartz, 2018).
- Para el objetivo de implementar un prototipo operativo, el indicador será la capacidad del equipo para ejecutar el flujo completo sin apoyo del estudiante. Al menos una persona de Customer Success debe ser capaz de generar el datamart, correr el notebook de scoring, obtener los archivos de salida y actualizar el Excel de resultados siguiendo los tutoriales entregados, procesando sin errores un corte mensual completo.

Las métricas se medirán al cierre del proyecto y, cuando sea posible, se revisarán en un corte posterior para verificar su estabilidad. El proyecto se considerará exitoso si se cumplen al menos cuatro de los cinco indicadores y se entregan el datamart, el portafolio de políticas y el prototipo operativo documentados.

6. Marco Conceptual

6.1. Fundamentos de CRM orientado a valor

El marco conceptual se apoya en la gestión de relaciones con clientes, entendida como un enfoque que combina estrategia, procesos y analítica de datos. La empresa organiza su información comercial y de uso del servicio para tomar decisiones que priorizan la retención y la expansión según el valor económico de cada cliente y su comportamiento observado en el tiempo. El foco se desplaza desde una mirada centrada en transacciones aisladas hacia una visión de ciclo de vida, en la que interesa cuánto aporta cada cliente durante toda su relación con la empresa y cómo es posible influir en esa trayectoria (Kumar and Reinartz, 2018).

En un CRM orientado a valor, los clientes no se tratan como un conjunto homogéneo. Se agrupan según variables como frecuencia de uso, nivel de pago, respuesta a las acciones comerciales y riesgo de baja. Estos grupos permiten diseñar estrategias diferentes: algunos segmentos se priorizan por su alto aporte actual, otros por su potencial de crecimiento y otros porque presentan alta probabilidad de pérdida. La combinación de valor económico y probabilidad de respuesta se convierte en un criterio central para decidir dónde concentrar los recursos de postventa y atención.

Este enfoque es especialmente relevante en modelos de suscripción y servicios recurrentes, donde pequeñas variaciones en la tasa de baja o en la tasa de expansión generan cambios importantes en los ingresos futuros. La literatura de CRM analítico indica que suele ser más eficiente invertir en retener y desarrollar clientes existentes que en adquirir nuevos clientes de manera indiscriminada, siempre que se cuente con métricas claras de valor y con herramientas que permitan identificar a los clientes más relevantes (Gupta et al., 2004, Kumar and Reinartz, 2018). En este contexto, la caracterización conductual de la cartera y su segmentación en función de riesgo y valor se conectan de forma directa con el problema de postventa, ya que permiten avanzar desde un trato uniforme hacia un tratamiento diferenciado y basado en datos.

6.2. Herramientas de ingeniería y analítica aplicadas

Las herramientas utilizadas en el proyecto pertenecen al marco de la ingeniería de datos y de la analítica de clientes. En primer lugar se encuentra el concepto de datamart, que proviene de la disciplina de inteligencia de negocios y del diseño de almacenes de datos. Un datamart corresponde a una vista temática de la información de la empresa, organizada en torno a un dominio específico, en este caso la relación con los clientes. Su propósito es ofrecer una base consistente y estable sobre la cual se puedan formular indicadores, análisis y modelos sin depender de los detalles técnicos de los sistemas operacionales (Kumar and Reinartz, 2018).

Sobre esta base se sitúan las herramientas de análisis descriptivo y de exploración de datos, que forman parte de la analítica de negocios tradicional. Estas herramientas tienen como función resumir el comportamiento de la cartera mediante indicadores, curvas de evolución y comparaciones entre grupos. Desde el punto de vista conceptual, su aporte es transformar

registros dispersos en una representación comprensible de cómo evolucionan los clientes, qué patrones de uso predominan y dónde aparecen diferencias relevantes entre segmentos (Gupta et al., 2004, Kumar and Reinartz, 2018).

En un nivel posterior se ubican los modelos de propensión, que pertenecen al campo de la estadística aplicada y de la minería de datos. Su objetivo teórico es relacionar un conjunto de características de los clientes con la probabilidad de que ocurra un evento de interés, como la baja o la respuesta a una oferta. La regresión logística es uno de los modelos canónicos en este ámbito, ya que permite estimar probabilidades a partir de variables explicativas y ofrece interpretaciones claras sobre el efecto de cada factor (Hosmer et al., 2013). En el contexto de gestión de clientes, estos modelos se usan para generar scores que ordenan la cartera según nivel de riesgo o probabilidad de respuesta.

La segmentación conductual combina la tradición del marketing analítico con técnicas de clasificación y agrupamiento. En lugar de tratar a todos los clientes por igual, se construyen segmentos que reflejan diferencias en patrones de uso, nivel de ingreso generado y riesgo de baja. Este enfoque se apoya en marcos como las matrices valor versus riesgo, que permiten identificar grupos como clientes de alto valor y alto riesgo o clientes de bajo valor y bajo riesgo. La justificación teórica es que estos segmentos tienen respuestas distintas a las acciones comerciales y, por lo tanto, requieren tratamientos diferenciados (Gupta et al., 2004, Inc., 2021, Kumar and Reinartz, 2018).

Finalmente, las reglas de decisión y las políticas comerciales derivadas de la analítica pertenecen al ámbito de la ingeniería de decisiones. Su función es traducir scores, segmentos e indicadores en acciones concretas para los equipos de contacto con clientes. Desde el marco conceptual de CRM orientado a valor, estas reglas actúan como un puente entre el análisis cuantitativo y la gestión diaria, al establecer de forma explícita qué tipo de intervención corresponde a cada grupo de clientes y bajo qué condiciones se recomienda su aplicación (Kumar and Reinartz, 2018).

6.3. Evaluación económica y métricas de desempeño

La evaluación económica del proyecto se apoya en métricas que relacionan el tamaño de la base de clientes, los ingresos recurrentes y el valor económico asociado a cada cuenta. Se define el número de clientes activos como N_{activos}, el ingreso mensual recurrente como MRR_{base} (suma de las mensualidades de todos los clientes activos) y el ingreso promedio por cuenta como

$$\text{ARPA} = \frac{\text{MRR}_{\text{base}}}{N_{\text{activos}}}.$$

La tasa de baja mensual $\text{Churn}_{\text{base}}$ es la proporción de clientes activos que dejan de serlo entre dos meses consecutivos. De forma análoga, la tasa de expansión mide el porcentaje de clientes que aumentan su pago mensual, distinguiendo una tasa de referencia $\text{TasaExp}_{\text{base}}$ y una tasa posterior a la aplicación de políticas $\text{TasaExp}_{\text{post}}$.

El valor económico de un cliente se resume mediante el valor de vida del cliente o CLV (Customer Lifetime Value). Bajo supuestos de tasa de baja mensual constante y margen

bruto estable, se utiliza la aproximación

$$\mathrm{CLV}_{\mathrm{simple}} = \mathrm{ARPA} \times \mathrm{Margen} \times \frac{1}{\mathrm{Churn}_{\mathrm{base}}},$$

donde Margen es el margen bruto promedio sobre los ingresos recurrentes. Cuando se requiere considerar el valor temporal del dinero, se puede usar una versión descontada con una tasa mensual i:

$$\mathrm{CLV}_{\mathrm{descontado}} = \frac{\mathrm{ARPA} \times \mathrm{Margen}}{\mathrm{Churn}_{\mathrm{base}} + i}.$$

La pérdida económica ligada a las bajas se expresa a nivel agregado como ingreso mensual perdido por churn,

$$\mathrm{MRR}_{\mathrm{perdido}} = \mathrm{MRR}_{\mathrm{base}} \times \mathrm{Churn}_{\mathrm{base}}.$$

El beneficio incremental del proyecto se mide comparando la situación antes y después del uso del modelo. La reducción de la tasa de baja desde $\mathrm{Churn}_{\mathrm{base}}$ a $\mathrm{Churn}_{\mathrm{post}}$ genera ingreso retenido adicional

$$\Delta\mathrm{MRR}_{\mathrm{retenido}} = \mathrm{MRR}_{\mathrm{base}} \times (\mathrm{Churn}_{\mathrm{base}} - \mathrm{Churn}_{\mathrm{post}}),$$

y el aumento de la tasa de expansión desde $\mathrm{TasaExp}_{\mathrm{base}}$ a $\mathrm{TasaExp}_{\mathrm{post}}$ genera ingreso adicional por expansión

$$\Delta\mathrm{MRR}_{\mathrm{exp}} = \mathrm{MRR}_{\mathrm{base}} \times (\mathrm{TasaExp}_{\mathrm{post}} - \mathrm{TasaExp}_{\mathrm{base}}).$$

A partir de estos términos se aproxima el beneficio anual esperado como

$$\text{Beneficio anual esperado} \approx (\Delta\mathrm{MRR}_{\mathrm{retenido}} + \Delta\mathrm{MRR}_{\mathrm{exp}}) \times \mathrm{Margen} \times 12 - \text{Costo del proyecto}.$$

En síntesis, se cuantifican N_{activos}, $\mathrm{MRR}_{\mathrm{base}}$, ARPA, $\mathrm{Churn}_{\mathrm{base}}$ y Margen, y se exige que el beneficio anual esperado supere el costo del proyecto y permita recuperar la inversión en un plazo razonable. Estos criterios se alinean con la literatura de CRM orientado a valor económico del cliente y con el uso de CLV como eje para priorizar decisiones de retención y expansión (Gupta et al., 2004, Kumar and Reinartz, 2018).

6.4. Elección metodológica para el caso de la empresa

La elección metodológica se apoya en la necesidad de contar con un marco estándar que ordene el ciclo completo de trabajo analítico. En este contexto se adopta el proceso CRISP-DM (Cross Industry Standard Process for Data Mining), que se ha utilizado de forma amplia en proyectos de minería de datos y analítica de negocios en distintos sectores. Su objetivo es ofrecer una guía estructurada que conecte la comprensión del negocio, la preparación de datos, el modelamiento y el uso de los resultados en la organización (Chapman et al., 2000).

CRISP-DM define seis fases principales, que se conciben como etapas iterativas y no como pasos rígidos. Cada fase tiene un propósito específico dentro del ciclo de descubrimiento de conocimiento y de construcción de modelos:

- Comprensión del negocio. En esta fase se define el problema desde la perspectiva de la organización. Se clarifican los objetivos que se desean alcanzar, las preguntas clave que se quieren responder y las restricciones relevantes. El resultado es una formulación clara del problema de negocio que la analítica debe abordar, junto con criterios de éxito medibles.

- Comprensión de los datos. Esta fase se orienta a conocer en detalle las fuentes de información disponibles. Se identifican las tablas y sistemas que contienen datos relevantes, se revisan sus estructuras y se exploran sus contenidos. También se detectan problemas de calidad, como datos faltantes, inconsistencias o sesgos, y se formulan hipótesis iniciales sobre el comportamiento que muestran los datos.

- Preparación de los datos. En esta etapa se construye el conjunto de datos que se utilizará para el modelamiento. Se seleccionan las variables relevantes, se integran fuentes distintas, se limpian los registros y se aplican transformaciones necesarias para que los datos queden en un formato adecuado para los modelos. En muchos proyectos esta fase consume una parte importante del esfuerzo total, ya que define la base sobre la que se construirá todo el análisis posterior.

- Modelado. La fase de modelado consiste en elegir técnicas de análisis apropiadas y aplicarlas al conjunto de datos preparado. Esto puede incluir modelos de clasificación, regresión, segmentación u otros métodos de minería de datos. En esta etapa se ajustan parámetros, se prueban diferentes configuraciones y se evalúan resultados preliminares. La relación con la fase de preparación de datos es iterativa: los hallazgos en el modelado pueden requerir ajustes en la forma de preparar los datos.

- Evaluación. En esta fase se analiza el desempeño de los modelos desde dos ángulos complementarios. Por un lado se revisan métricas cuantitativas, como indicadores de discriminación, error o estabilidad. Por otro lado se evalúa si los modelos responden de forma adecuada a los objetivos de negocio definidos al inicio. Esto puede implicar revisar supuestos, interpretar coeficientes, analizar grupos de clientes específicos y considerar la viabilidad de uso de los resultados por parte de los equipos de la organización.

- Despliegue. La fase de despliegue aborda cómo se incorporan los resultados del proyecto en la operación. Puede incluir la generación periódica de reportes, la creación de flujos de scoring, la entrega de listados priorizados a usuarios de negocio o la integración con sistemas existentes. También contempla la planificación de actualizaciones de modelos, el monitoreo de su desempeño en el tiempo y la documentación necesaria para asegurar continuidad. El foco está en transformar los modelos en herramientas efectivas para la toma de decisiones (Chapman et al., 2000, Kumar and Reinartz, 2018).

Como marco alternativo se considera el proceso de descubrimiento de conocimiento en bases de datos, conocido como KDD (Knowledge Discovery in Databases). Este enfoque organiza el trabajo en etapas de selección, preprocesamiento, transformación, minería de datos y evaluación de patrones. Su origen está en la comunidad de minería de datos y se

centra con fuerza en la extracción de estructuras interesantes desde grandes volúmenes de información. Conceptualmente pone el acento en las operaciones técnicas de preparación y en la aplicación de algoritmos de minería, con una visión más compacta de las etapas previas y posteriores al modelamiento.

La decisión de adoptar CRISP-DM por sobre KDD responde a la naturaleza del problema y a las necesidades de gestión de la empresa. En un contexto de CRM orientado a valor, donde el objetivo es apoyar decisiones de retención y expansión en un equipo específico, resulta clave contar con un marco que otorgue un espacio explícito a la comprensión del negocio, a la definición de criterios de éxito y al despliegue operativo de los resultados. CRISP-DM ofrece una estructura más detallada en estas fases, lo que facilita la alineación con los objetivos de gestión de clientes, la comunicación con usuarios de negocio y la planificación de cómo se usarán los modelos en ciclos recurrentes. KDD aporta una visión sólida sobre las tareas de minería de datos, pero presenta un menor énfasis en la conexión sistemática con el negocio y en la etapa de despliegue, por lo que se considera menos adecuado como guía principal para un proyecto cuyo foco está en integrar la analítica en la operación de Customer Success y en la gestión de clientes de una empresa de servicios como Reservo (Chapman et al., 2000, Kumar and Reinartz, 2018).

7. Metodología

La metodología del proyecto se basa en el proceso CRISP-DM, que organiza el trabajo en seis fases: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Cada fase agrupa tareas que permiten avanzar desde la definición del problema de gestión hasta la entrega de un prototipo operativo de uso interno (Chapman et al., 2000, Kumar and Reinartz, 2018).

7.1. Fase 1: Comprensión del negocio

En esta fase se define el problema desde la perspectiva de la empresa y se alinean las expectativas de los actores involucrados.

- Levantar el contexto de Reservo, incluyendo el modelo de suscripción, el rol de Customer Success y Post-venta, y las principales características de la cartera actual.
- Clarificar el problema de gestión asociado a la baja de clientes y a la necesidad de usar mejor la información disponible para prevenirla y aprovechar oportunidades de expansión.
- Formular el objetivo general y los objetivos específicos del proyecto, asegurando su conexión con causas identificadas del problema de postventa y con necesidades concretas de gestión.
- Definir indicadores de éxito para el modelo, el datamart, la segmentación y el prototipo operativo, y acordar con la empresa el formato de los entregables principales.
- Cuantificar una línea base económica de la cartera mediante el número de clientes activos, el ingreso mensual recurrente, el ingreso promedio por cuenta, la tasa de bajas y la pérdida anual de ingresos asociada, que servirá como referencia para evaluar el impacto del proyecto.

7.2. Fase 2: Comprensión de los datos

En esta fase se identifican y se analizan las fuentes de datos que sostendrán el modelo y las segmentaciones.

- Elaborar un inventario de tablas relevantes en la base de datos de Reservo, considerando clientes, uso de la plataforma, cambios de estado administrativos, planes y rubros.
- Revisar la estructura y calidad de cada tabla, analizando llaves, granularidad, cobertura temporal, presencia de datos faltantes, inconsistencias y valores atípicos.
- Definir un calendario de cortes mensuales que represente el estado de la cartera en distintos momentos y sirva de base para la construcción del datamart y de la etiqueta de baja.

- Establecer definiciones operativas de cliente activo, cliente en onboarding, cliente bloqueado y cliente dado de baja, y documentar criterios de inclusión y exclusión de registros.

7.3. Fase 3: Preparación de los datos

En esta fase se construye el datamart analítico y se genera la matriz de características que se utilizará en los modelos.

- Diseñar la estructura del datamart mensual con clave compuesta por identificador de cliente y mes de corte, y definir las uniones necesarias entre tablas de clientes, uso, cambios de estado, planes y rubros.
- Calcular variables de contexto, valor, uso y fricción a partir de las tablas de origen, siguiendo reglas simples y reproducibles que faciliten la interpretación por parte del negocio.
- Definir y construir la etiqueta de baja a horizonte mensual, garantizando que las variables explicativas solo utilicen información disponible hasta el mes de corte y que las bajas consideradas sean efectivas.
- Tratar valores faltantes y valores extremos mediante reglas documentadas, y dejar el conjunto de datos en un formato adecuado para su uso en herramientas de modelamiento.

7.4. Fase 4: Modelado

En esta fase se construyen y se ajustan los modelos que estiman el riesgo de baja y que sirven de base para la segmentación conductual.

- Seleccionar un algoritmo principal de clasificación supervisada, en este caso una regresión logística binaria, y justificar su elección por interpretabilidad y capacidad para producir probabilidades.
- Definir una estrategia de partición temporal en conjuntos de entrenamiento, validación y prueba, que respete el orden de los meses y simule el uso futuro del modelo.
- Implementar un flujo de preprocesamiento que incluya imputación, transformación y codificación de variables, preferentemente encapsulado en un pipeline reproducible.
- Entrenar y ajustar la regresión logística con diferentes configuraciones de parámetros, incorporando técnicas de manejo de desbalance y calibración de probabilidades, y dejando documentadas las opciones evaluadas.

7.5. Fase 5: Evaluación

En esta fase se analiza el desempeño del modelo y se conecta con los indicadores de éxito definidos en la comprensión del negocio.

- Evaluar el modelo en el conjunto de prueba utilizando métricas de discriminación y de focalización, como AUC y porcentaje de bajas capturadas en los grupos de mayor riesgo estimado.
- Revisar la calibración de las probabilidades y el comportamiento del modelo en segmentos relevantes, como países, rubros o tipos de plan, para asegurar estabilidad y coherencia.
- Comparar los resultados con los umbrales definidos en los indicadores de éxito y determinar si la calidad del modelo es suficiente para priorizar acciones de retención y expansión.
- Documentar conclusiones y recomendaciones sobre el modelo final, incluyendo sugerencias de ajustes futuros y lineamientos para su monitoreo en uso operativo.

7.6. Fase 6: Despliegue y políticas de negocio

En esta fase se define cómo se usarán los resultados del modelo en la operación y se diseña el prototipo operativo que articula analítica y gestión comercial.

- Diseñar un flujo mensual de scoring que permita aplicar el modelo sobre la cartera actualizada, a partir del datamart mensual, y generar tablas con probabilidades de baja, rangos de riesgo y variables de contexto.
- Especificar y construir los artefactos operativos necesarios para el uso del modelo por parte de Customer Success, incluyendo scripts de generación del datamart, un notebook de scoring y archivos de Excel para revisión de resultados.
- Definir una propuesta de segmentación conductual que combine riesgo, valor económico y variables de uso, y asociar a cada segmento un conjunto preliminar de políticas comerciales recomendadas.
- Preparar material de apoyo y lineamientos de adopción, como tutoriales y sesiones de explicación con los equipos de Customer Success y Post-venta, junto con criterios básicos para el monitoreo del prototipo.

8. Desarrollo y Resultados

8.1. Fase 1: Comprensión del negocio

8.1.1. Contexto de Reservo y modelo de suscripción

En la primera tarea se levantó el contexto del negocio de Reservo y su modelo de suscripción. Se revisaron los planes de servicio disponibles, los principales rubros atendidos y la presencia geográfica de la cartera. A partir de esta revisión se confirmó que la empresa opera como proveedor de software como servicio para profesionales y centros de salud pequeños y medianos en Chile, Argentina, Colombia y México, con una cartera cercana a 3.500 clientes activos distribuidos en cuatro planes de precio mensual. También se describió el rol de los equipos de Customer Success y Post-venta en la relación continua con los clientes, identificando sus responsabilidades en soporte, acompañamiento y retención.

8.1.2. Problema de gestión asociado a la baja de clientes

La segunda tarea consistió en clarificar el problema de gestión que motiva el proyecto. Se analizó el flujo completo del cliente desde la captación hasta la baja, distinguiendo las etapas de adquisición, venta, onboarding, cliente activo y cliente inactivo. Con apoyo de los diagramas de proceso incluidos en los anexos se describió cómo se produce hoy la baja y qué señales previas suelen aparecer. A partir de las métricas internas se constató una tasa de bajas mensuales cercana al 2,4 por ciento, un crecimiento moderado de las expansiones y esfuerzos de postventa concentrados en reaccionar cuando el cliente ya está cerca de abandonar. Este análisis llevó a formular el problema central como una falta de caracterización y segmentación conductual de la cartera activa, que impide diferenciar el trato según riesgo y potencial económico.

8.1.3. Definición del objetivo general y de los objetivos específicos

En la tercera tarea se tradujo el diagnóstico anterior en objetivos formales para el proyecto. Se definió un objetivo general orientado a diseñar y validar un modelo analítico que permita estimar el riesgo de baja a nivel de cliente y apoyar decisiones de retención y expansión. A partir de este objetivo se derivaron objetivos específicos relacionados con la identificación de variables de comportamiento relevantes, la construcción de un datamart estructurado, la definición de segmentos de clientes según riesgo y valor, el diseño de un portafolio de políticas comerciales diferenciadas y la implementación de un prototipo operativo que acerque el modelo al trabajo diario de Customer Success. Cada objetivo se vinculó explícitamente con una causa del problema de postventa identificada en la etapa anterior.

8.1.4. Indicadores de éxito y definición de entregables

La cuarta tarea se enfocó en definir cómo se medirá el éxito del proyecto y en acordar los entregables principales con la empresa. Se establecieron indicadores para la calidad del modelo, como su capacidad para distinguir entre clientes que se dan de baja y aquellos que se mantienen, y para la cobertura del datamart sobre la cartera activa. También se definieron

métricas de focalización, como la concentración de bajas en el grupo de clientes con mayor riesgo estimado, y criterios de adopción del prototipo, como la capacidad del equipo de Customer Success para ejecutar el flujo de uso sin apoyo del estudiante.

Finalmente se acordaron los entregables clave del proyecto: el datamart mensual documentado, el modelo de riesgo ajustado, la propuesta de segmentación conductual, el portafolio de políticas comerciales asociado y la carpeta de uso con tutoriales y materiales de traspaso para los equipos internos.

8.1.5. Línea base económica y evaluación preliminar

La quinta tarea consistió en cuantificar una línea base económica de la cartera aplicando las métricas definidas en el marco conceptual a los datos internos de la empresa. Primero se fijó el número de clientes activos como $N_{\text{activos}} \approx 3.500$. El ingreso anual recurrente observado se estimó en torno a \$2.465.400.000, por lo que el ingreso mensual recurrente base se aproxima como

$$\text{MRR}_{\text{base}} \approx \frac{2.465.400.000}{12} \approx 205.450.000.$$

Con este valor se calculó el ingreso promedio por cuenta mediante

$$\text{ARPA} = \frac{\text{MRR}_{\text{base}}}{N_{\text{activos}}} \approx \frac{205.450.000}{3.500} \approx 58.700.$$

Luego se consideró la tasa de bajas mensuales observada, cercana al 2,4 por ciento, que se interpreta como $\text{Churn}_{\text{base}} = 0{,}024$. Aplicada sobre la base de clientes, esta tasa implica que cada mes se dan de baja aproximadamente

$$N_{\text{bajas}} \approx N_{\text{activos}} \times \text{Churn}_{\text{base}} \approx 3.500 \times 0{,}024 \approx 84.$$

El ingreso mensual que se pierde por estas bajas se aproxima mediante

$$\text{MRR}_{\text{perdido}} = \text{MRR}_{\text{base}} \times \text{Churn}_{\text{base}} \approx 205.450.000 \times 0{,}024 \approx 4.930.800,$$

lo que proyectado a un año corresponde a una pérdida cercana a

$$\text{MRR}_{\text{perdido anual}} \approx 4.930.800 \times 12 \approx 59.200.000.$$

Estas cifras entregan el orden de magnitud del problema económico asociado al churn actual de la cartera.

A partir de esta línea base se analizaron escenarios simples de mejora, utilizando la expresión de ingreso retenido incremental. Si el proyecto lograra reducir la tasa de bajas desde 0,024 a 0,020, la diferencia sería $\Delta\text{Churn} = 0{,}004$ y el ingreso mensual adicional retenido se aproximaría por

$$\Delta\text{MRR}_{\text{retenido}} = \text{MRR}_{\text{base}} \times \Delta\text{Churn} \approx 205.450.000 \times 0{,}004 \approx 821.800,$$

lo que equivale a cerca de $821.800 \times 12 \approx 9.861.600$ de ingreso retenido en un año. De

manera similar, una mejora de solo 0,1 puntos porcentuales en la tasa de bajas (ΔChurn = 0,001) representa aproximadamente

$$\Delta \mathrm{MRR}_{\mathrm{retenido}} \approx 205.450.000 \times 0{,}001 \approx 205.450,$$

es decir, alrededor de $205.450 \times 12 \approx 2.465.400$ de ingreso adicional retenido al año.

Estos cálculos aplican de forma directa las definiciones de $\mathrm{MRR}_{\mathrm{base}}$, ARPA, $\mathrm{Churn}_{\mathrm{base}}$ y $\mathrm{MRR}_{\mathrm{perdido}}$ del marco conceptual y entregan una referencia cuantitativa que se utilizará más adelante para interpretar los resultados del modelo y de las políticas de retención y expansión.

8.2. Fase 2: Comprensión de los datos

8.2.1. Inventario de fuentes y tablas principales

La comprensión de los datos comenzó con un inventario detallado de las tablas operacionales que contienen la información necesaria sobre los clientes, su uso de la plataforma y su contexto comercial. Se identificó como tabla central a `cliente_cliente`, que almacena la ficha maestra de cada cuenta. En esta tabla se revisaron las columnas `id` (identificador único del cliente), `fecha_creacion` (fecha de alta), `demo` (indicador de cuenta demo), `cuenta_lista` (indica si la cuenta se considera válida para análisis), `pais` (país del cliente), `mensualidad` (monto mensual asociado) y `plan_reservo_id` (referencia al plan contratado). Estas columnas se reconocen como la base para definir el universo de clientes reales, su localización y una primera aproximación a su aporte económico.

Para reconstruir la historia de estados de cada cliente se consideró la tabla `ReservoInterno_cambioestadocliente`, que registra cada evento administrativo relevante. En ella se analizaron las columnas `cliente_id`, `fecha` y `tipo`, donde el tipo puede tomar valores como `'Baja'`, `'Bloqueo'` o `'Desbloqueo'`. Esta tabla se identificó como la fuente principal para entender en qué momento un cliente pasa de activo a inactivo, cuándo sufre bloqueos y cuándo se revierten decisiones anteriores.

El uso de la plataforma se estudió a partir de dos tablas relacionadas: `appointment_ticket` y `cliente_servicio`. La primera contiene las citas agendadas en el sistema, con columnas como `id` y `fecha`. La segunda permite asociar cada cita a un cliente mediante la relación `appointment_ticket.ofertante_id` → `cliente_servicio.id` → `cliente_servicio.cliente_id`. De esta forma se identificó el camino que permite pasar desde un registro de cita a la cuenta que efectivamente usa la plataforma.

Para el contexto comercial se consideraron las tablas `cliente_planreservo` y `cliente_rubro`. En `cliente_planreservo` se revisaron las columnas `id`, `nombre` y `rubro_id`, que describen los planes comerciales ofrecidos y su asociación a rubros. En `cliente_rubro` se revisaron las columnas `id` y `nombre`, que entregan la clasificación sectorial del cliente. Además se consideró la tabla `Fichas_registroaccesoficha`, que registra accesos a fichas clínicas con columnas como `cliente_id` y `fecha`, y tablas de extras como `ReservoInterno_clientesextras` y `ReservoInterno_extras`, que permiten identificar contrataciones adicionales. Con este inventario se definió un conjunto de tablas que cubren identidad, valor, uso básico, uso

avanzado y contexto de los clientes.

8.2.2. Estructura y calidad de las tablas

Una vez identificado el conjunto de tablas principales se analizó su estructura y calidad. En `cliente_cliente` se comprobó que `id` es único por registro y que los campos `demo` y `cuenta_lista` permiten separar las cuentas internas o de prueba de las cuentas que forman parte de la cartera comercial. Se revisó la distribución de `pais`, distinguiendo los principales mercados en que opera Reservo, y se examinó la columna `mensualidad`, donde se observaron casos con valores cero o nulos que corresponden a situaciones especiales, como promociones o ajustes. Estos casos se dejaron documentados porque afectan la calidad de las variables de valor económico.

En la tabla `ReservoInterno_cambioestadocliente` se verificó que cada fila representa un evento con fecha asociada para un `cliente_id` determinado. Se revisó la coherencia temporal de las secuencias de `tipo`, observando patrones con múltiples `'Bloqueo'` y `'Desbloqueo'` para un mismo cliente. También se identificaron casos de `'Baja'` seguidos de `'Desbloqueo'`, lo que sugiere que no todas las bajas registradas corresponden a salidas definitivas. Estas observaciones motivaron la necesidad de definir reglas claras para distinguir entre bajas efectivas y bajas revertidas.

En las tablas de uso, `appointment_ticket` y `cliente_servicio`, se revisó la consistencia de la relación entre citas y clientes. Se comprobó que la cadena de llaves permite asignar cada cita a un `cliente_id` y se analizó la distribución temporal de `fecha` en las citas. Se detectaron periodos con alta concentración de actividad, coherentes con la expansión de la base, y también clientes con muy pocas citas, que actúan como posibles candidatos a patrones de bajo uso. En `cliente_planreservo` y `cliente_rubro` se revisó que las llaves `id` sean consistentes y que los nombres de planes y rubros reflejen las categorías comerciales vigentes. Se observó que algunos clientes no tienen rubro explícito o no están asociados a un plan estándar, lo que se registró como potencial fuente de datos faltantes en las variables de contexto. En las tablas de extras y de registros de fichas se constató una fuerte concentración en un subconjunto de clientes, lo que indica que estas fuentes entregan información valiosa sobre uso avanzado pero no están presentes en toda la cartera.

8.2.3. Calendario de cortes mensuales

Además de revisar tablas y columnas, la fase de comprensión de datos incluyó la decisión de trabajar con un esquema de cortes mensuales. La idea central es observar a los clientes en fechas de referencia regulares y reconstruir, para cada mes, su estado y su comportamiento reciente. Conceptualmente se definió un rango de meses de análisis y se estableció que cada mes calendario tendría un corte asociado, cercano al inicio del mes. En torno a cada corte se acordó la necesidad de disponer de historia suficiente hacia atrás para medir uso de la plataforma y eventos de fricción, por ejemplo ventanas de noventa días para contar citas o bloqueos.

Este calendario mensual se concibió como eje temporal común para todas las vistas posteriores. En cada mes de corte se buscará responder preguntas como cuántos clientes están activos, cuánto utilizan el sistema, qué planes tienen contratados y qué eventos de cambio de

estado presentan. También a partir de este calendario se definirá, en fases posteriores, cómo se calcula la ocurrencia de una baja en el mes siguiente al corte. La fase de comprensión de datos se centró en justificar este enfoque a nivel conceptual y en asegurar que la historia disponible en las tablas operacionales es suficiente para sostenerlo.

8.2.4. Definiciones operativas de estados de cliente

Finalmente se avanzó en la definición operativa de los estados de cliente que se utilizarán a lo largo del proyecto. A partir de `cliente_cliente` se acordó que el universo de análisis estará compuesto por los registros con `demo = 0`, `cuenta_lista = 1` y `fecha_creacion` válida, lo que excluye cuentas de prueba y registros internos. Sobre este universo se propuso una definición de cliente activo en un mes de referencia basada en la ausencia de bajas efectivas vigentes antes del corte. En términos prácticos, si un cliente no presenta ninguna baja registrada antes del corte, o si toda baja anterior fue seguida por un evento que la revierte, se considera que el cliente está activo en ese mes.

En relación con la baja, se distinguió entre bajas registradas y bajas efectivas. Se definió baja registrada como cualquier evento de tipo `'Baja'` en `ReservoInterno_cambioestado-cliente`. Para que una baja se considere efectiva se requiere que no exista, en un plazo razonable posterior, un evento de tipo `'Desbloqueo'` que indique reversión. Cuando una baja va seguida de un desbloqueo rápido, se interpreta como una interrupción temporal o como una corrección administrativa y no como una pérdida real de cliente. Esta distinción es clave, porque las tasas de baja que se usarán más adelante deben reflejar salidas definitivas.

También se acordó una interpretación operacional de otros estados. El tramo de onboarding se asocia a los primeros meses a partir de `fecha_creacion` o de la primera facturación, y se consideró relevante para analizar comportamientos de clientes nuevos y su probabilidad de estabilizarse como activos. El estado de bloqueado se vincula a eventos de tipo `'Bloqueo'` y se entiende como una señal de fricción que puede preceder a una baja efectiva. Por último se documentaron criterios de inclusión y exclusión de casos especiales, como cuentas sin país definido, clientes con historia muy corta o planes atípicos. Estas definiciones no construyen aún las variables del modelo, pero fijan el marco conceptual que se utilizará en la fase siguiente para preparar el datamart y las etiquetas de baja.

8.3. Fase 3: Preparación de los datos

En esta fase se construye el datamart analítico a nivel cliente–mes y se generan las variables que alimentan la matriz de características. El trabajo se organiza en cuatro tareas: diseño del panel mensual, cálculo de variables de contexto, valor, uso y fricción, definición de la etiqueta de baja a horizonte mensual y tratamiento de valores faltantes y extremos.

8.3.1. Diseño de la estructura del datamart mensual

La preparación de los datos se basa en un script SQL principal que genera un panel con granularidad cliente por mes de corte, donde cada fila corresponde a una combinación `id_cliente` × `mes_corte`. El rango temporal se define mediante parámetros de inicio y fin:

- `@inicio`: primer día del primer mes analizado.

- `@fin`: primer día del último mes analizado.
- `@hist_inicio`: fecha mínima para cambios de estado, definida como `@inicio` menos 90 días.
- `@inicio_buf`: fecha mínima para uso de plataforma, también 90 días antes de `@inicio`.
- `@fin_mas1`: fecha máxima para cambios de estado, extendida dos meses más allá de `@fin` para cubrir la etiqueta a horizonte T+1.

Con estos parámetros se construye un calendario de cortes mensuales mediante un CTE recursivo que genera una fila por cada fecha de corte entre `@inicio` y `@fin`. En paralelo se define el conjunto de clientes candidatos a partir de la tabla `cliente_cliente`. En este paso se filtran solo los clientes reales y válidos, usando las condiciones `demo = 0`, `cuenta_lista = 1` y `fecha_creacion` no nula. El resultado contiene las columnas `id_cliente` y `alta`, que corresponden al identificador del cliente y a su fecha de alta.

Luego se extrae el historial de cambios de estado desde la tabla `ReservoInterno_cambioestadocliente`. Este paso selecciona los registros para los clientes definidos como candidatos dentro de la ventana temporal acotada por `@hist_inicio` y `@fin_mas1`. Cada fila contiene `id_cliente`, `fecha_cambio` y `tipo_cambio`, donde el tipo incluye eventos como `'Baja'`, `'Bloqueo'` o `'Desbloqueo'`.

A partir del calendario de cortes y de los candidatos se genera una base intermedia que combina `mes_corte` e `id_cliente` solo cuando existe historia previa de cambios de estado para ese cliente. Sobre esta base se determina si un cliente está activo en un corte dado. Para cada combinación se busca la última fecha de cambio con `tipo_cambio = 'Baja'` anterior al corte. Si no existe baja previa, el cliente se considera activo. Si existe, se revisa si hay un evento de tipo `'Desbloqueo'` entre la fecha de baja y el corte. Si se encuentra un desbloqueo en ese intervalo, la baja se considera revertida y el cliente se mantiene activo; si no se encuentra, la baja se interpreta como vigente y el cliente se excluye del conjunto de activos en ese corte.

Los pasos posteriores reutilizan esta estructura para incorporar información de uso, fricción, contexto y etiqueta. El cálculo de uso se basa en las tablas `appointment_ticket` y `cliente_servicio`; la fricción se resume a partir de los cambios de estado administrativos, y el contexto se obtiene desde `cliente_cliente`, `cliente_planreservo` y `cliente_rubro`. La consulta final combina estas vistas mediante uniones por `mes_corte` e `id_cliente` y produce el panel mensual que alimenta la matriz de características.

8.3.2. Construcción de variables de contexto, valor, uso y fricción

La segunda tarea consiste en definir las variables que describen a cada cliente en cada mes de corte. Estas variables se calculan en el script principal y se detallan en el documento de variables del datamart. El panel resultante contiene once columnas principales: `id_cliente`, `mes_corte`, `pais`, `rubro`, `plan_nombre`, `arpa_proxy`, `tenure_meses`, `citas_30d`, `recencia_uso_dias`, `bloqueos_90d` y `churn_T1`.

Las variables de identificación y calendario son:

- `id_cliente`: identificador único del cliente, tomado desde `cliente_cliente.id`.
- `mes_corte`: primer día del mes de referencia.

Las variables de contexto se derivan de la información comercial:

- `pais`: país del cliente, proveniente de `cliente_cliente.pais`.
- `plan_nombre`: nombre del plan vigente, obtenido mediante la relación `cliente_cliente.plan_reservo_id` → `cliente_planreservo.id` → `cliente_planreservo.nombre`.
- `rubro`: rubro asociado al plan, calculado como `cliente_planreservo.rubro_id` → `cliente_rubro.id` → `cliente_rubro.nombre`.

Las variables de valor económico son:

- `arpa_proxy`: aproximación del ingreso mensual por cliente. Se toma desde `cliente_cliente.mensualidad` y se reemplazan los valores cero por nulos mediante `NULLIF (mensualidad, 0)` para evitar confundir promociones o ajustes con ingresos reales.
- `tenure_meses`: antigüedad del cliente al mes de corte, medida en meses, calculada con `TIMESTAMPDIFF(MONTH, fecha_creacion, mes_corte)`.

Las variables de uso reciente de la plataforma se obtienen a partir de las tablas `appointment_ticket` y `cliente_servicio`. Primero se agrupa el uso diario por cliente, y luego se calculan:

- `citas_30d`: número de citas en los 30 días previos al corte. Para cada combinación `mes_corte`, `id_cliente` se suman las citas diarias en el intervalo de 30 días anteriores. Si no hay registros de uso en esa ventana, el resultado se define como cero.
- `recencia_uso_dias`: días desde la última cita registrada antes del corte. Se calcula como la diferencia entre `mes_corte` y la máxima fecha de uso en los 90 días anteriores. Si no hubo uso en los 90 días previos, el valor queda nulo en esta etapa.

La fricción reciente se resume a partir de los cambios de estado administrativos:

- `bloqueos_90d`: número de bloqueos en los 90 días previos al corte. Para cada cliente activo y corte se cuentan los eventos con `tipo_cambio = 'Bloqueo'` en la ventana de 90 días anteriores; si no existen bloqueos en ese periodo, se asigna cero.

La combinación de estas variables permite describir, para cada cliente y mes, su contexto comercial, su aporte económico aproximado, su nivel de uso reciente y sus eventos de fricción, manteniendo una estructura mensual uniforme.

8.3.3. Definición de la etiqueta de baja a horizonte mensual

La tercera tarea consiste en definir la etiqueta binaria que se usará como resultado en el modelamiento. Esta etiqueta, llamada `churn_T1`, indica si un cliente activo en un corte determinado presenta una baja efectiva en el mes siguiente.

El cálculo se apoya en dos pasos conceptuales. Primero se identifican las bajas registradas en el mes siguiente a cada corte. Para cada cliente se revisan los eventos de tipo `'Baja'` en `ReservoInterno_cambioestadocliente` cuya fecha cae entre `mes_corte` y el mismo día del mes siguiente. Si hay varias bajas en el periodo, se toma la primera fecha de baja del mes.

En segundo lugar se distingue entre bajas registradas y bajas efectivas. Para cada baja registrada se verifica si existe un evento de tipo `'Desbloqueo'` para el mismo cliente con fecha posterior a la baja y anterior al término del mes. Si existe un desbloqueo en esa ventana, la baja se considera revertida y se descarta a efectos de la etiqueta. Si no existe, la baja se clasifica como efectiva.

Con esta definición se construye la etiqueta `churn_T1`. Para cada cliente activo en un corte dado se pregunta si en el mes siguiente existe una baja efectiva según la regla anterior. Si la respuesta es afirmativa, `churn_T1` toma valor 1; en caso contrario, toma valor 0. Esta construcción asegura que todas las variables explicativas de un registro usan solo información observada hasta el mes de corte, mientras que el resultado se define con lo que ocurre en el mes siguiente, evitando fuga temporal.

8.3.4. Tratamiento de valores faltantes y valores extremos

La última tarea de la fase revisa la calidad del panel resultante y aplica transformaciones basadas en el análisis exploratorio de datos. El análisis mostró que las variables numéricas presentan distribuciones asimétricas y algunas tienen colas largas con valores extremos. También se detectaron proporciones moderadas de valores nulos en ciertas columnas.

En cuanto a valores faltantes, la variable `rubro` presenta una fracción de nulos, `recencia_uso_dias` muestra ausencia de datos para clientes sin uso reciente, `arpa_proxy` tiene algunos casos sin mensualidad válida y `plan_nombre` presenta un número menor de registros sin plan asociado. Para las variables categóricas `pais`, `plan_nombre` y `rubro` se acordó imputar una categoría explícita que represente valor desconocido, de modo que la ausencia de información quede registrada y no se pierdan filas. Para `arpa_proxy` se definió imputar a una mediana coherente con el plan del cliente cuando se dispone de esa información, o a la mediana global cuando no es posible, y se creó un indicador binario que marca los casos imputados. En `recencia_uso_dias`, los nulos corresponden a clientes sin uso en los últimos 90 días; en estos casos se decidió imputar el valor máximo operativo de la ventana, igual a 90 días, y mantener un indicador que señala la ausencia total de uso reciente.

Respecto de los valores extremos, la variable `arpa_proxy` muestra una distribución con cola larga hacia la derecha, con pocos clientes que alcanzan valores muy superiores al resto. Para evitar que estos casos dominen los análisis se definió un recorte en percentiles altos y luego se aplicó una transformación logarítmica de tipo

$$\log\Big(1 + \texttt{arpa_proxy}\Big),$$

que comprime la cola y estabiliza la variabilidad. Se mantiene además un indicador que señala si el valor original fue recortado.

La variable `tenure_meses` también presenta una cola larga, con clientes que superan varios años de antigüedad, mientras que la mayoría se concentra bajo los dos años. El análisis mostró que el riesgo de baja es alto en los primeros meses y disminuye de forma no lineal a medida que avanza la antigüedad. Por esta razón se capó `tenure_meses` en un percentil alto y se definieron bandas ordinales que representan tramos de antigüedad, además de considerar una transformación de raíz cuadrada sobre la versión continua capada, con el objetivo de suavizar diferencias extremas entre clientes muy antiguos y clientes de antigüedad media.

La variable de uso `citas_30d` se caracteriza por una asimetría marcada, con muchos clientes en niveles bajos de actividad y un grupo reducido con cientos o miles de citas mensuales. Para hacer manejable esta distribución se aplicó un recorte en el percentil alto, seguido de la transformación

$$\log\Big(1 + \texttt{citas_30d}\Big).$$

Además se construyeron indicadores que reflejan situaciones relevantes para la gestión, como actividad muy baja o casos en los que el valor fue recortado por exceso.

La variable `recencia_uso_dias` mostró una relación fuerte con la probabilidad de baja: clientes con pocos días desde la última cita presentan una tasa de baja muy baja, mientras que clientes con más días sin uso acumulan tasas de baja mucho mayores. Para capturar esta estructura se decidió capar la recencia en 90 días, imputar nulos a ese mismo valor y crear varias representaciones derivadas. Se definieron bandas operativas que permiten identificar umbrales naturales para alertas y se calculó un puntaje continuo de frescura del tipo

$$\texttt{fresh} = \frac{1}{1 + \texttt{recencia_uso_dias}},$$

que asigna mayor valor a clientes con uso muy reciente y valores cercanos a cero a clientes inactivos.

En cuanto a la fricción, la variable `bloqueos_90d` presenta una fuerte inflación de ceros: la mayoría de los clientes no registra bloqueos en los últimos 90 días, mientras que un grupo pequeño acumula uno o más eventos. El análisis mostró que el salto de riesgo más marcado se produce al pasar de uno a dos bloqueos recientes. Por ello se decidió tratar esta variable como un conteo discreto pequeño, capando el número de bloqueos en un máximo de tres y generando indicadores que marcan la presencia de al menos un bloqueo y la presencia de dos o más bloqueos. Esta representación permite capturar el efecto umbral de la fricción sin introducir transformaciones continuas de difícil interpretación.

Finalmente se revisó que todas las transformaciones respetaran el principio temporal del panel. Las imputaciones, recortes, bandas y variables derivadas se definen usando solo información disponible hasta `mes_corte` y no utilizan la etiqueta `churn_T1`. De este modo, la matriz de características resultante queda en un formato adecuado para su uso en las fases de modelado, sin fuga de información y con reglas de tratamiento documentadas que pueden reproducirse en futuros cortes mensuales.

8.4. Fase 4: Modelado

En esta fase se construyen y se ajustan los modelos que estiman el riesgo de baja mensual y que sirven de base para la segmentación conductual. El trabajo se organiza en cuatro tareas: selección del algoritmo de clasificación, definición del esquema de partición temporal y tamaño muestral, implementación del flujo de preprocesamiento en un pipeline reproducible y entrenamiento con calibración de probabilidades.

8.4.1. Selección del algoritmo y definición del problema de clasificación

El problema de modelamiento se formula como una clasificación binaria con horizonte mensual. Para cada fila del panel cliente–mes se busca estimar la probabilidad de que el cliente, estando activo en el mes de corte, presente una baja efectiva en el mes siguiente. La variable objetivo es la etiqueta construida en la fase anterior, denominada `churn_T1`, que toma valor 1 cuando ocurre una baja efectiva en el mes siguiente y 0 en caso contrario.

Se elige como algoritmo principal una regresión logística binaria con regularización. Esta familia de modelos resulta adecuada por varias razones. Permite trabajar con variables numéricas transformadas y variables categóricas codificadas mediante indicadores, mantiene una relación lineal en el espacio de los logaritmos de las razones de probabilidad y entrega de manera directa una probabilidad entre 0 y 1 para cada observación. La forma funcional simple facilita la interpretación de los coeficientes y la identificación de direcciones de efecto de cada grupo de variables, lo que es relevante para un proyecto orientado a decisiones de gestión y no solo a predicción.

La regresión logística se implementa con regularización de tipo L2 para controlar la complejidad del modelo y reducir el riesgo de sobreajuste, especialmente en presencia de variables derivadas y dummies. El modelo incluye la opción de ponderar las clases mediante el parámetro `class_weight='balanced'`, que ajusta automáticamente los pesos de la clase minoritaria y de la clase mayoritaria en función de la prevalencia observada de bajas. De esta forma se busca que el algoritmo no ignore los eventos de churn pese a que representan una proporción pequeña del total de observaciones.

Otros algoritmos más complejos, como métodos de ensamble basados en árboles de decisión, se consideran como alternativas posibles para una etapa futura, pero no se adoptan en esta versión del prototipo. La prioridad es contar con un modelo interpretable, estable y fácil de explicar a las áreas de negocio, con un desempeño suficiente para ordenar a los clientes según su riesgo y servir como base para políticas comerciales diferenciadas.

8.4.2. Partición temporal y tamaño muestral para entrenamiento y calibración

La construcción del modelo se realiza respetando la estructura temporal de la información. El panel cliente–mes generado en la fase anterior contiene 43 965 observaciones y 1 073 eventos de baja, con una prevalencia global cercana a 2,44 %, coherente con el análisis exploratorio. Sobre esta base se define una partición en tres conjuntos: entrenamiento, desarrollo para calibración y prueba final.

El conjunto de entrenamiento agrupa 19 485 observaciones, con cerca de 497 eventos de baja y una tasa en torno a 2,55 %. El conjunto de desarrollo o calibración incluye 7 821

observaciones, con aproximadamente 186 eventos y una tasa de 2,38 %. El conjunto de prueba contiene 16 659 observaciones y alrededor de 390 eventos, con una tasa de 2,34 %. Los cortes temporales se fijan de manera que el entrenamiento utilice meses anteriores, el desarrollo considere los meses inmediatamente previos al periodo de prueba y el conjunto de prueba represente meses recientes, simulando el uso futuro del modelo.

El modelo utiliza ocho fuentes principales de información: `arpa_proxy`, `citas_30d`, `recencia_uso_dias`, `bloqueos_90d`, `tenure_meses`, `plan_nombre`, `pais` y `rubro`. Después de las transformaciones definidas en la fase de preparación, cada una de estas fuentes se descompone en varias columnas derivadas, por ejemplo banderas de nulo y de capeo, transformaciones continuas y categorías codificadas. El número total de grados de libertad efectivos del modelo se estima en torno a 35 si se consideran solo las variables numéricas y el plan, y puede llegar a valores entre 41 y 46 cuando se agregan las dummies de país y rubro con categorías agrupadas.

Con estos tamaños de muestra y esta complejidad efectiva se evalúan las condiciones de estabilidad del modelo mediante el criterio de eventos por variable. En el conjunto de entrenamiento, con cerca de 497 eventos de baja, se obtiene un cociente cercano a 62 eventos por cada una de las ocho fuentes de información y alrededor de 14 eventos por grado de libertad cuando se consideran los 35 parámetros efectivos. Incluso en escenarios con más dummies de país y rubro el cociente se mantiene cercano o por sobre 10 eventos por grado de libertad, que es un umbral habitual para la regresión logística en contextos de baja prevalencia. Esta revisión respalda que el tamaño de muestra disponible es suficiente para estimar un modelo estable con la estructura elegida.

8.4.3. Implementación del flujo de preprocesamiento y del pipeline de modelado

Las transformaciones definidas en la fase de preparación se encapsulan en un pipeline de modelado que integra, en un mismo flujo, el preprocesamiento y la regresión logística. Este enfoque garantiza que todas las operaciones sobre las variables se ajusten solo con datos de entrenamiento y se apliquen luego de forma idéntica en desarrollo, prueba y producción.

El pipeline se organiza en dos bloques principales. El primero corresponde a un conjunto de transformadores específicos por variable para las columnas numéricas. Entre ellos se encuentran componentes para `arpa_proxy`, `citas_30d`, `recencia_uso_dias`, `bloqueos_90d` y `tenure_meses`. Cada transformador aplica las reglas descritas en la fase anterior: imputación de valores faltantes, capeo en percentiles altos, creación de indicadores de nulo y de valor capado, cálculo de transformaciones continuas como logaritmos o raíces cuadradas y construcción de bandas ordinales cuando corresponde. Las salidas numéricas se escalan luego con un esquema robusto basado en mediana y rango intercuartílico para reducir la influencia de valores extremos.

El segundo bloque agrupa las variables categóricas `plan_nombre`, `pais` y `rubro`. Estas columnas se tratan mediante codificación one hot, después de aplicar reglas simples de agrupación de categorías poco frecuentes. De esta manera el modelo recibe un conjunto acotado de dummies que representan los planes principales, los países con presencia relevante y los rubros más frecuentes en la cartera, manteniendo un equilibrio entre granularidad y estabilidad

de las estimaciones.

Sobre estos bloques se construye un objeto de transformación conjunto que se aplica a la matriz de entrada. El resultado es una matriz numérica que reúne todas las variables derivadas en un formato adecuado para la regresión logística. El listado de columnas de entrada se mantiene en un arreglo denominado `_DEFAULT_FEATURES`, que asegura que el mismo conjunto de variables se utilice en todas las etapas del proyecto. Antes de cada ajuste o *scoring* se verifican las columnas presentes en los datos mediante una función de chequeo, lo que permite detectar de manera temprana cualquier diferencia entre la base histórica y las bases que se utilicen en el futuro.

8.4.4. Entrenamiento, calibración y elección del modelo final

Una vez definidos el algoritmo, la partición temporal y el pipeline de transformaciones, se procede al entrenamiento del modelo. Primero se separa el conjunto de entrenamiento en matrices de entrada y salida mediante las columnas `_DEFAULT_FEATURES` y `churn_T1`. Luego se ajusta el pipeline completo sobre estos datos, de modo que en una sola instrucción se aprenden los parámetros de imputación, capeo, escalado, codificación de categorías y la regresión logística con regularización y ponderación de clases.

Después del ajuste inicial se realizan evaluaciones preliminares en el conjunto de prueba sin calibración adicional. Estas evaluaciones se basan en métricas habituales para problemas de baja prevalencia, como el área bajo la curva ROC y el área bajo la curva de precisión contra recall, además de medidas de concentración de eventos en los deciles de mayor probabilidad. El objetivo de esta etapa es verificar que la combinación de variables y transformaciones entrega una capacidad razonable para ordenar a los clientes desde menor a mayor riesgo de baja.

El siguiente paso corresponde a la calibración de probabilidades. El pipeline ajustado en entrenamiento se envuelve en un esquema de calibración fuera de muestra utilizando el conjunto de desarrollo. Se emplea un clasificador calibrado que mantiene fijos los parámetros de la regresión logística y aprende una función de ajuste adicional sobre las probabilidades crudas. Según el número de eventos disponibles en el conjunto de desarrollo se utiliza calibración isotónica, cuando la muestra de bajas es suficiente, o calibración sigmoidal cuando el número de eventos es menor. La evaluación posterior en el conjunto de prueba considera métricas de calibración como el Brier score, la pendiente y el intercepto de calibración y comparaciones entre probabilidades predichas y tasas observadas en grupos de clientes.

Durante el proceso se exploran variantes del modelo en términos de intensidad de regularización y selección de subconjuntos de variables transformadas. Las combinaciones que no mejoran de forma clara la discriminación o la calibración se descartan. El modelo final corresponde a la regresión logística regularizada integrada en el pipeline de transformaciones y envuelta en el calibrador entrenado con el conjunto de desarrollo. Este modelo produce, para cada cliente activo en un mes de corte, una probabilidad mensual de baja que sirve como insumo principal para las fases siguientes de evaluación económica, segmentación conductual y diseño de políticas comerciales.

8.5. Fase 5: Evaluación

En esta fase se analiza el desempeño del modelo y se conecta con los indicadores de éxito definidos en la comprensión del negocio. Se revisa la capacidad de discriminación y de focalización, la calibración de las probabilidades, la estabilidad en segmentos relevantes y la suficiencia del modelo para uso operativo.

8.5.1. Desempeño global en el conjunto de prueba

La evaluación principal se realiza sobre el conjunto de prueba definido en la fase de modelado. El modelo calibrado alcanza un valor de ROC–AUC cercano a 0,825, lo que indica una capacidad sólida para separar clientes que harán baja efectiva de aquellos que permanecerán activos. La curva de precisión–recall muestra una PR–AUC de aproximadamente 0,10 frente a una tasa base de eventos de 0,023, por lo que el área bajo la curva es más de cuatro veces superior al nivel que se obtendría con un ranking aleatorio. Esto confirma que el ordenamiento por probabilidad entrega una ganancia clara en priorización de clientes en riesgo.

El análisis por deciles de riesgo en el conjunto de prueba muestra que el primer decil concentra una tasa de baja cercana a 11 %, frente a la tasa promedio de 2,34 %, lo que representa un *lift* cercano a 4,8. En ese primer decil se acumula cerca del 48 % de todos los eventos de churn. Al considerar el 20 % superior del ranking (deciles 1 y 2) la captura acumulada llega a alrededor del 68 % de las bajas, el 30 % superior captura cerca del 80 % y el 40 % superior alcanza valores en torno a 86–87 %. El 50 % superior del ranking concentra aproximadamente el 91 % de los eventos. Estos resultados muestran que la masa de bajas se concentra en la parte alta del score y que el modelo permite focalizar la atención en una fracción reducida de la cartera con alta cobertura de eventos.

Desde una perspectiva operativa se revisan dos umbrales de trabajo. El primero corresponde al 20 % superior de la cartera en el conjunto de prueba, con un punto de corte cercano a 0,043 en probabilidad. En ese umbral el modelo alcanza un recall de alrededor de 0,695 y una precisión cercana a 0,081, es decir, casi el 70 % de las bajas se encuentra dentro de ese grupo y la tasa de eventos en el subconjunto priorizado es más de tres veces la tasa base. El segundo umbral fija un número absoluto de clientes, en torno a 600 casos con probabilidades más altas. En este punto la precisión se eleva a valores cercanos a 0,148 y el recall se sitúa alrededor de 0,228. Este escenario representa un grupo más acotado de clientes, con una tasa de bajas mucho mayor, útil para acciones intensivas con capacidad limitada.

8.5.2. Calibración de probabilidades y estabilidad por segmentos

Además de la discriminación, se analiza la calibración de las probabilidades en el conjunto de prueba. El Brier score global se sitúa en torno a 0,022, lo que indica un error cuadrático medio bajo. La pendiente de calibración es cercana a 0,89, lo que refleja una ligera sobreconfianza: las probabilidades muy altas y muy bajas tienden a estar un poco más cerca del promedio real. El intercepto se aproxima a -0,30 y la probabilidad media predicha (alrededor de 0,0229) es muy similar a la observada (en torno a 0,0234), con una diferencia absoluta menor a 0,001. La tabla de confiabilidad por grupos de probabilidad muestra concordancia

razonable en casi todos los tramos; en el grupo de probabilidad más alta la tasa observada de baja es algo superior a la predicha, lo que confirma una leve subpredicción en la cola alta, pero dentro de márgenes manejables.

La calibración se revisa también por tipo de plan, país y rubro. Por plan, las diferencias entre probabilidad media predicha y observada son cercanas a cero en los planes Básico y Reservo. En el plan Individual la tasa real de baja es levemente superior a la estimada, con un error absoluto cercano a 0,01, mientras que en el plan Enterprise se observan diferencias pequeñas pero con poca cantidad de casos. Por país, el comportamiento en Chile, que concentra la mayor parte de la muestra, es estable, con probabilidades predichas y observadas prácticamente iguales. En países con pocos clientes de prueba, como algunos mercados secundarios, los errores de calibración son mayores, lo que se interpreta como resultado natural de tamaños muestrales pequeños más que de un problema estructural del modelo.

Por rubro, Medicina/Salud y Centro de estética presentan una calibración muy alineada, con errores absolutos cercanos a cero. En Psicología/Psiquiatría la tasa de baja real es levemente superior a la estimada, con un error en torno a 0,01, lo que indica una pequeña subpredicción, pero mantiene un nivel aceptable para uso operativo. En rubros con menos observaciones la variación es mayor, de nuevo por efecto del bajo volumen.

8.5.3. Pruebas de robustez por país y rubro

Para evaluar la robustez del modelo se realizan experimentos adicionales en distintos subconjuntos de la cartera, utilizando el mismo modelo entrenado y calibrado. En los segmentos con mayor volumen de datos, como el conjunto global, Chile, Medicina/Salud, Chile más Medicina/Salud y la combinación Chile–México–Colombia, las métricas de discriminación se mantienen en torno a ROC–AUC 0,82–0,83, con PR–AUC similares al valor global y con un top 20 % del ranking que captura alrededor del 70 % de las bajas. Esto indica que el modelo conserva su capacidad de ranking en los subsegmentos que representan el núcleo del negocio.

En México, donde el número de observaciones es menor, el modelo muestra un ROC–AUC cercano a 0,76. Aunque este valor es algo inferior al global, sigue por encima de 0,75, lo que resulta útil para priorización. La PR–AUC es aproximadamente tres veces la tasa base de churn en ese país y el top 20 % de clientes por score captura alrededor del 70 % de las bajas, con una precisión que supera el 11 %. Estos resultados sugieren que, pese al menor volumen, el modelo entrega señales aprovechables para la operación.

Colombia es el único segmento donde el rendimiento baja de manera clara. El ROC–AUC se sitúa en torno a 0,62, el top 20 % del ranking captura del orden del 23 % de las bajas y las métricas de calibración muestran mayor error medio. Este comportamiento coincide con el bajo número de clientes y de eventos disponibles para ese país, lo que limita la capacidad de aprender patrones específicos y genera ruido. En lugar de entrenar un modelo exclusivo para Colombia, se concluye que, con los datos actuales, es preferible utilizar el modelo global como referencia y considerar la mejora de este segmento como trabajo futuro sujeto a mayor volumen de información.

En conjunto, las pruebas por país y rubro muestran que el modelo es estable y consistente en los segmentos principales de la empresa y que las diferencias más marcadas aparecen solo donde el tamaño de muestra es reducido. Esto respalda la decisión de trabajar con un modelo

único a nivel regional como piloto.

8.5.4. Conclusiones sobre suficiencia del modelo para uso operativo

Los resultados de discriminación y de focalización cumplen y superan los umbrales definidos en los indicadores de éxito. El ROC–AUC se ubica por encima del valor mínimo propuesto para un modelo útil en este contexto y el porcentaje de bajas capturadas en el 20 % superior del ranking supera ampliamente el 40 % exigido, alcanzando valores cercanos al 70 %. La calibración global es adecuada, con diferencias promedio pequeñas entre probabilidades predichas y observadas, y la estabilidad por plan y rubro es buena en los segmentos con mayor volumen. Las pruebas por país confirman que el modelo es sólido en Chile y en el conjunto Latam y que las limitaciones se concentran en mercados de menor tamaño.

Con base en esta evidencia, se considera que el modelo final es suficiente para apoyar decisiones de retención y expansión en la empresa. El score mensual de riesgo de baja puede utilizarse para priorizar clientes en acciones de Customer Success, siempre que se acompañe de monitoreo continuo de métricas clave y de una revisión periódica de la calibración, en particular en segmentos con menor número de clientes. El detalle de las políticas comerciales asociadas a los distintos niveles de riesgo se desarrolla en las fases siguientes de despliegue del prototipo operativo.

8.6. Fase 6: Despliegue y políticas de negocio

En esta fase se define cómo se usarán los resultados del modelo en la operación y se concreta un prototipo operativo que conecta el trabajo analítico con la gestión comercial. El diseño considera el flujo mensual de scoring, los artefactos entregados a la empresa, la segmentación conductual asociada a políticas preliminares y los lineamientos de adopción para Customer Success.

8.6.1. Flujo mensual de scoring sobre la cartera actualizada

El flujo de uso parte en la base de datos transaccional de la empresa. Cada vez que se desea actualizar el modelo se ejecuta el script `Datamart Principal Memoria_Act.sql` sobre el esquema `reservov2`, utilizando una herramienta de consulta MySQL como DataGrip conectada mediante túnel SSH a la base productiva. El único parámetro que el usuario debe modificar es la fecha de corte `@fin`, que se fija como el primer día del mes siguiente al periodo que se quiere analizar. El script genera un resultado tabular que contiene, para todos los clientes activos al cierre, las columnas necesarias para el modelo en formato cliente–mes.

Ese resultado se exporta a un archivo `CSV`, que se renombra como `database_act.csv` y se almacena en la carpeta de trabajo indicada para el modelo. Luego se abre el cuaderno `Colab_para_Customer_Success.ipynb` en Google Colab, donde se cargan dos archivos: `database_act.csv` (datamart actualizado) y `database1.csv` (base histórica usada en el entrenamiento). Con estos insumos se ejecuta la celda de producción del cuaderno, que aplica el modelo calibrado sobre el corte seleccionado, calcula las probabilidades de baja a uno y tres meses, asigna rangos cualitativos de riesgo, construye el ranking global y genera archivos de salida en formato `CSV`.

El usuario descarga el archivo de salida elegido, lo renombra como `salida_modelo_1.csv` y lo guarda en la carpeta `Colab py`. Finalmente se abre el Excel `Clientes en riesgo de fuga - modelo`, se presiona el botón de "Actualizar todo" en la pestaña de datos y el libro actualiza todas sus consultas de Power Query para leer el nuevo `salida_modelo_1.csv`. De este modo el flujo de scoring queda encapsulado en una secuencia de pasos clara: actualización del datamart, ejecución del modelo en Colab y actualización del Excel para la revisión de resultados.

8.6.2. Artefactos operativos y carpeta de uso para Customer Success

Para facilitar el despliegue se construye la Carpeta de uso Customer Success, que organiza todos los elementos necesarios en tres subcarpetas principales. La carpeta Archivo `sql` contiene el script `Datamart Principal Memoria_Act.sql`, que encapsula las consultas a las tablas de clientes, uso, cambios de estado, planes y rubros. Esta pieza permite regenerar el datamart mensual sin necesidad de escribir código adicional; los usuarios solo deben ajustar la fecha de corte y exportar el resultado.

La carpeta `Colab py` almacena el cuaderno `Colab_para_Customer_Success.ipynb`, el archivo histórico `database1.csv` y el archivo de salida `salida_modelo_1.csv`. En el cuaderno se concentran las definiciones del pipeline de preprocesamiento, el modelo calibrado y el módulo de scoring operativo descrito en la fase anterior. El diseño separa explícitamente la etapa de entrenamiento, que no se ejecuta en uso diario, de la etapa de inferencia, que es la única que el equipo debe activar. El archivo `database1.csv` se mantiene fijo como referencia histórica y solo se reemplaza `database_act.csv` en cada ciclo.

La carpeta Excel de resultado contiene el archivo `Clientes en riesgo de fuga - modelo`, configurado con Power Query para leer siempre el `salida_modelo_1.csv` ubicado en `Colab py`. En el editor de consultas se deja fijada la ruta al archivo y se documenta cómo modificarla en caso de cambio de ubicación. El Excel presenta tablas y vistas filtrables por país, plan, rubro, rango de riesgo y ranking, lo que permite a Customer Success priorizar clientes sin interactuar con código ni con la base de datos. De esta forma, la carpeta de uso reúne en un solo lugar el script SQL, el cuaderno de modelado y el Excel de explotación, junto con los documentos de apoyo asociados.

"'latex

8.6.3. Segmentación conductual y políticas preliminares

La salida del modelo se utiliza para definir una propuesta de segmentación conductual basada en combinaciones de riesgo de baja y valor económico aproximado. A partir de las columnas de probabilidad mensual y trimestral, y de los rangos cualitativos de riesgo, se identifican grupos como alto riesgo y alto valor, alto riesgo y valor medio, riesgo medio con potencial de expansión y riesgo bajo pero valor alto. Estas combinaciones se construyen utilizando la probabilidad a un mes como referencia principal para priorización inmediata y la probabilidad a tres meses para identificar casos donde la baja puede ocurrir dentro del trimestre.

El valor económico se aproxima mediante la variable `arpa_proxy`, derivada de la mensualidad del cliente, y se complementa con la antigüedad en meses y con el plan contratado.

Sobre esta base se definen umbrales operativos que permiten ubicar a los clientes en bandas de valor sin necesidad de cálculos adicionales en las herramientas de negocio. La segmentación incluye también información de país y rubro, de modo que las políticas puedan adaptarse a contextos comerciales distintos cuando sea necesario.

Los motivos de baja observados entre enero de 2023 y julio de 2024 permiten refinar esta segmentación por rubro. En Medicina/Salud, un 33 % de las bajas se explica por cierre de local o quiebra y un 18 % por bloqueos de 40 días, mientras que en Centros de estética la combinación es 27 % por cierre y 19 % por bloqueos. En Psicología/Psiquiatría el cierre de local concentra 31 % de las bajas y el costo beneficio 14 %. En Odontología el principal motivo es la competencia con 23 %, seguido por cierre de local con 21 % y bloqueos con 16 %. En Salón de belleza y barbería se observa una mezcla de cierre de local (18 %), bloqueos (18 %) y cambio a la competencia (13 %), además de un 11 % asociado a costo beneficio. Estos porcentajes entregan una probabilidad relativa de cada motivo dentro de cada rubro y ayudan a priorizar hipótesis de acción cuando un cliente aparece en alto riesgo.

Algo similar ocurre al analizar las razones de baja por plan. En los planes Individual y Básico, el cierre de local representa entre 27 % y 32 % de las bajas y los bloqueos de 40 días entre 16 % y 19 %, seguidos por motivos de costo beneficio en torno a 11–14 %. En el plan Reservo, el cierre de local concentra 35 % de las bajas, la competencia 14 % y los bloqueos 13 %. En el plan Enterprise se observa un peso mayor de temas de producto y requisitos sanitarios: 26 % por cierre de local, 19 % por software y 11 % por falta de permisos sanitarios, junto con porcentajes menores de bloqueos, contactabilidad y costo beneficio (7 % cada uno). Estas diferencias sugieren que la misma probabilidad de baja no debe interpretarse igual en todos los planes, ya que los motivos predominantes cambian con el nivel de servicio.

A partir de esta evidencia, las políticas preliminares se ajustan tanto por riesgo como por rubro y plan. Para segmentos de alto riesgo y alto valor en rubros donde la competencia es un motivo relevante (por ejemplo, Odontología y parte de Psicología/Psiquiatría), se recomiendan contactos uno a uno enfocados en comparar beneficios, revisar funcionalidades clave y reforzar la propuesta de valor frente a alternativas del mercado. En rubros y planes donde los bloqueos de 40 días tienen un peso alto, como Medicina/Salud, Centros de estética, planes Individual y Básico, se propone un seguimiento sistemático de clientes bloqueados, revisión de causas técnicas y acompañamiento cercano después de la reactivación. Cuando el cierre de local o la falta de permisos sanitarios explican gran parte de las bajas, como en Medicina/Salud, Reservo y Enterprise, se reconoce que la capacidad de retención es menor y se prioriza el seguimiento de clientes en proceso de expansión o apertura de nuevas sedes para aprovechar oportunidades futuras.

En segmentos de riesgo medio con alto potencial de expansión, especialmente en planes con motivos de costo beneficio relevantes, se sugieren acciones orientadas a aumentar el uso percibido y a conectar mejor el precio con los beneficios concretos del software, mediante demostraciones de funcionalidades, revisión de reportes y ajustes de configuración. Para los segmentos de riesgo bajo se plantea un seguimiento liviano, usando la información de motivos de baja para detectar señales tempranas (por ejemplo, falta de adopción del software o problemas de contactabilidad) antes de que se conviertan en causas de salida. Estas políticas se presentan como guía inicial para el equipo de Customer Success y Post-venta, que podrá ir

refinando las acciones recomendadas a medida que se acumule experiencia sobre la respuesta de cada grupo de clientes. “‘

8.6.4. Material de apoyo, pruebas en vivo y adopción del prototipo

El despliegue del prototipo se acompaña de un conjunto de tutoriales escritos y materiales audiovisuales que documentan el flujo de principio a fin. Se elabora un tutorial de implementación del modelo que describe la estructura de la Carpeta de uso Customer Success y referencia de manera integrada los documentos específicos para conexión a la base de datos, configuración de Colab y uso del Excel. Se redacta un tutorial de uso diario dirigido al equipo de Customer Success, donde se detallan los pasos para ejecutar el script de datamart, exportar `database_act.csv`, cargar los archivos en Colab, generar las salidas, renombrar `salida_modelo_1.csv` y actualizar el Excel. Este documento enfatiza que los nombres de archivo y las rutas deben mantenerse fijos y que no se deben modificar las consultas internas ni el código del cuaderno.

De manera complementaria se preparan tutoriales específicos para cada herramienta: una guía de conexión de DataGrip a la base de datos de producción mediante túnel SSH, con los parámetros de host, puerto, usuario, llave y base por defecto; una guía de configuración de Google Colab y de carga del cuaderno `Colab_para_Customer_Success.ipynb` en Google Drive; y una guía de uso del Excel de resultados que explica cómo fijar el origen de datos en Power Query y cómo operar el archivo solo con el comando “Actualizar todo”. Cada tutorial incluye versiones en video que muestran el flujo en pantalla, de modo que el equipo pueda seguir los pasos sin necesidad de conocimientos técnicos avanzados.

Durante el cierre del proyecto se realizan pruebas en vivo del flujo completo, utilizando bases actualizadas de producción. Estas pruebas permiten verificar que el datamart se genera correctamente con la fecha de corte deseada, que el cuaderno de Colab acepta los archivos sin errores y que el Excel refleja los cambios una vez cargado el nuevo `salida_modelo_1.csv`. Los resultados de estas ejecuciones se discuten con el equipo de Customer Success, que valida la lectura de las columnas clave y la utilidad de los filtros por riesgo, plan y país.

Como resultado, se deja instalada una primera versión del prototipo operativo, lista para ser utilizada en un periodo inicial de evaluación interna. La empresa planifica usar el modelo en modo piloto durante los meses de diciembre, enero y febrero, con foco en revisar la coherencia de los clientes priorizados, ajustar las políticas propuestas y detectar necesidades adicionales de segmentación. La implementación completa en los sistemas de la empresa queda fuera del alcance temporal del proyecto, pero todos los elementos necesarios para esa etapa se entregan documentados: scripts, cuadernos, archivos de resultado, tutoriales y recomendaciones de monitoreo. De este modo, el trabajo desarrollado en la memoria deja una base sólida para que la organización avance desde el prototipo hacia una integración más profunda en sus procesos de gestión de clientes.

9. Discusiones

9.1. Decisiones de diseño del modelo

Las decisiones de diseño del modelo se tomaron en un contexto donde la empresa necesita resultados accionables y comprensibles. La elección de una regresión logística como algoritmo principal privilegia la lectura directa de los coeficientes y de los efectos de cada variable. Esta elección reduce la posibilidad de obtener el mejor desempeño numérico frente a modelos más complejos, pero facilita que equipos no técnicos puedan revisar por qué un cliente aparece con mayor probabilidad de baja y cómo se relaciona ese riesgo con su uso de la plataforma, su plan o su historial de bloqueos. La discusión se centra en este equilibrio entre precisión y transparencia, que en Reservo tiene un peso especial por la necesidad de alinear a Customer Success, Ventas y Marketing en torno a una misma herramienta.

El horizonte mensual T+1 responde a la forma en que se gestiona la cartera. La facturación y muchas decisiones comerciales se revisan en ciclos de mes a mes. Un horizonte más largo podría captar mejor ciertos patrones de abandono, pero dificultaría medir cambios en la tasa de bajas después de aplicar políticas. La derivación de una probabilidad T+3 a partir de T+1 abre un espacio intermedio. No se entrena un modelo distinto, pero se obtiene una señal que mira el trimestre y permite planificar acciones que requieren más tiempo. La discusión gira en torno a cuánto peso dar a cada horizonte en la práctica y cómo combinar decisiones de corto y mediano plazo sin dispersar el esfuerzo del equipo.

Otra decisión relevante es el uso de un modelo global para toda la región. Un solo modelo reduce la complejidad operativa y aprovecha la información de todos los países, lo que ayuda a estabilizar los parámetros. Al mismo tiempo, los tamaños de muestra no son homogéneos. Chile y México concentran más observaciones que otros mercados. Esto plantea preguntas sobre posibles sesgos hacia los patrones de esos países y sobre la conveniencia futura de modelos específicos por país o por grupo de rubros. La memoria deja este punto abierto como una línea de trabajo posterior, ligada al crecimiento de la base y a la necesidad de mayor precisión en segmentos particulares.

La implementación del prototipo en Colab y Excel también refleja una decisión de diseño. Se privilegia el uso de herramientas que el equipo ya conoce y que no requieren cambios en la infraestructura tecnológica. El flujo de SQL, cuaderno en Colab y Excel permite operar el modelo con pasos claros y repetibles. A cambio, se acepta una dependencia mayor de la disciplina operativa y de la correcta ejecución de cada paso manual. En la discusión surgen ideas como una futura integración directa en los sistemas de la empresa o el uso de tableros de BI conectados a la salida del modelo, pero estas opciones quedan fuera del alcance temporal de la memoria.

9.2. Impacto esperado en la operación y rol de Customer Success

El modelo introduce una forma distinta de priorizar la cartera. La existencia de probabilidades de baja y de un ranking asociado permite que Customer Success deje de tratar a todos los clientes activos de la misma manera y concentre parte del tiempo del equipo en grupos donde el riesgo es más alto. En la práctica esto implica revisar cómo se distribuyen las horas

disponibles, cuántos contactos proactivos se pueden realizar al mes y qué tipo de acciones son razonables para cada segmento de valor. La discusión considera que la capacidad del equipo es limitada y que no todas las cuentas del ranking podrán recibir la misma atención.

La segmentación conductual construida en el proyecto agrega una capa adicional al combinar riesgo, valor económico y contexto comercial. El cruce con los motivos de baja observados por rubro y por plan permite adaptar las acciones de manera más fina. Por ejemplo, en rubros y planes donde el cierre de local explica una fracción importante de las bajas, la capacidad de retención es menor y tiene más sentido concentrar esfuerzos en clientes en expansión o en centros con proyectos de crecimiento. En rubros donde la competencia o el costo beneficio son motivos frecuentes, un cliente en alto riesgo invita a revisar con más detalle la propuesta de valor, los precios y el uso efectivo de funcionalidades frente a alternativas del mercado. Esta lectura combinada hace que el mismo nivel de probabilidad no signifique exactamente lo mismo en todos los segmentos.

La coordinación entre áreas se vuelve un aspecto central. El ranking de riesgo, los rangos cualitativos y la información de motivos de baja permiten que Marketing, Ventas y Customer Success hablen un lenguaje común. Es posible diseñar campañas de retención y expansión dirigidas a grupos específicos, como clientes de alto riesgo y alto valor en rubros sensibles a la competencia, o clientes con riesgo medio pero alto potencial de crecimiento en planes donde el costo beneficio aparece como motivo recurrente. Al mismo tiempo, el proyecto recuerda que la probabilidad de baja no es el único factor relevante. Cada acción tiene un costo en tiempo, descuentos, visitas o beneficios entregados. La memoria muestra el costo del churn con claridad, pero aún no cuantifica de manera detallada el costo de las acciones de retención. Esta asimetría abre un espacio natural para que la empresa experimente con pilotos acotados y mida no solo la reducción de bajas, sino también el costo asociado a cada tipo de intervención.

En este contexto se vuelve importante revisar las prácticas actuales de Customer Success. El modelo puede mostrar que ciertos clientes aparecen de forma recurrente en los tramos de mayor riesgo, lo que invita a analizar qué tipo de contactos se han realizado, qué mensajes se utilizan y qué barreras enfrentan los ejecutivos para implementar cambios sugeridos. La discusión sugiere evaluar las acciones no solo a partir de los resultados numéricos, sino también considerando el contexto de la empresa, la carga operativa y los cambios imprevistos en el mercado. Cambios de precio de la competencia, nuevas funcionalidades o campañas agresivas pueden reducir la efectividad de acciones que en principio parecían bien dirigidas según el modelo.

9.3. Comportamiento del cliente y límites del modelo

El proyecto se apoya en variables de uso de la plataforma, bloqueos, antigüedad, plan, país y rubro, entre otras. Estas variables capturan parte importante del comportamiento observable, pero no agotan la realidad del cliente. Existen decisiones de abandono que responden a motivos subjetivos o estratégicos difíciles de reflejar en la base: cambios en la administración del centro, preferencias personales por otra herramienta, recomendaciones de colegas, percepción de marca o situaciones económicas internas. En esos casos, el modelo

puede clasificar a un cliente como de riesgo bajo y, aun así, observarse una baja repentina. La discusión reconoce estos límites y plantea que siempre habrá un espacio de imprevisibilidad que no se puede eliminar solo con más datos estructurados.

Los motivos de baja registrados por los ejecutivos son una fuente valiosa de contexto, pero también presentan restricciones. Categorías amplias como costo beneficio o otra razón pueden agrupar situaciones heterogéneas, y la forma de registrar la información puede variar entre personas y en el tiempo. El proyecto utiliza estos motivos para orientar las políticas por rubro y plan, pero evita incorporarlos directamente como predictores del modelo para no amplificar posibles sesgos de registro. La interpretación de los motivos se entiende mejor como insumo cualitativo para las decisiones de Customer Success que como variable estrictamente cuantitativa.

Intentar modelar todas las fuentes posibles de variación con el conjunto actual de datos podría empujar al modelo hacia un sobreajuste. Añadir variables muy específicas o construidas a partir de pocos casos puede hacer que el modelo se adapte a patrones que no se repetirán en el futuro. Esto mejoraría las métricas en el conjunto histórico, pero podría empeorar la capacidad de generalizar. La memoria opta por un conjunto moderado de variables con sentido de negocio y deja fuera señales más idiosincráticas que, por ahora, se interpretan mejor desde la experiencia del equipo que desde la estadística. La discusión propone mantener esta prudencia aun cuando se incorporen nuevas fuentes de información.

Dentro de las variables que se consideran prometedoras aparece la idea de registrar visitas presenciales a los centros. Hoy esa información no está integrada en las tablas que alimentan al modelo, por lo que se representa como una columna sin datos. Se anticipa que, en el futuro, un registro sistemático de visitas podría ayudar a entender mejor la relación entre contacto presencial y riesgo de baja y podría convertirse en un predictor relevante para ciertos rubros. La discusión sugiere mantener esa columna en el datamart como espacio reservado, de modo que cuando la empresa comience a registrar visitas no sea necesario rediseñar toda la estructura.

Otra línea que se menciona es el estudio de la competencia y de su oferta de software. Durante el proyecto se trabaja sobre todo con datos internos. Analizar con más detalle las funcionalidades, precios y modelos de servicio de otros proveedores permitiría interpretar mejor algunos patrones de churn. Por ejemplo, si muchos clientes bajan en un periodo coincidente con una campaña específica de un competidor, esa información podría explicar comportamientos que el modelo atribuye hoy solo a variables internas de uso. La discusión identifica esta comparación como una fuente relevante de contexto que la empresa puede explotar en análisis posteriores.

9.4. Limitaciones de datos y riesgos en el uso del prototipo

El prototipo depende de la calidad de los registros de bajas y bloqueos, ya que estas variables definen la etiqueta de salida. Errores en la codificación de estados, reversiones no registradas o demoras en la actualización pueden distorsionar la estimación del riesgo. Algo similar ocurre con las fechas de inicio de pago, las mensualidades y la identificación de clientes activos al corte. La memoria asume que estas fuentes son suficientemente confiables para el

ejercicio, pero la discusión señala que sería útil reforzar procesos de control interno sobre estos datos, sobre todo si el modelo pasa a integrarse de manera más automatizada en la operación.

El flujo operativo actual exige disciplina en la ejecución de varios pasos: correr el script SQL con la fecha correcta, exportar el archivo, subirlo a Colab, ejecutar el cuaderno y actualizar el Excel. Cada paso abre una posible fuente de error humano. La discusión plantea que, mientras no exista una integración más directa, será necesario designar responsables claros, documentar los procedimientos y mantener rutinas de revisión para evitar que pequeños cambios en nombres de archivos o rutas de carpetas interrumpan el uso del modelo.

Por último, se reconoce que el entorno en que opera Reservo es dinámico. Nuevos competidores, cambios de plan, ajustes de precio o modificaciones en la propuesta de valor pueden alterar los patrones de churn y hacer que el modelo pierda vigencia si no se reentrena. El proyecto deja un conjunto de herramientas y un prototipo funcional, pero el mantenimiento futuro dependerá de que la empresa incorpore estas tareas en su ciclo de trabajo. La discusión, en este sentido, no cierra el tema, sino que señala un conjunto de riesgos y decisiones pendientes que acompañarán el uso del modelo en los próximos años.

10. Conclusiones

10.1. Cumplimiento de los objetivos e indicadores

El primer objetivo, referido a la obtención de un conjunto validado de variables de comportamiento, se cumple a través del rendimiento del modelo de regresión logística. El conjunto formado por las variables `arpa_proxy`, `tenure_meses`, `citas_30d`, `recencia_uso_dias`, `bloqueos_90d`, `plan_nombre`, `pais` y `rubro` demuestra ser suficiente para capturar información relevante sobre el riesgo de abandono: el valor de ROC–AUC cercano a 0,825 en el conjunto de prueba supera con holgura el umbral de 0,70 definido como indicador de éxito. Esto valida empíricamente la selección de variables y las deja como base adecuada para futuras extensiones del modelo.

El segundo objetivo, relativo a la construcción de un datamart estructurado, también se considera cumplido. El datamart mensual integra en una sola vista la información de clientes, uso, fricción y contexto, y se genera mediante un único script parametrizable. La validación sistemática de columnas en el módulo de scoring y la revisión de cobertura muestran que, en los cortes utilizados, la gran mayoría de la cartera activa dispone de todas las variables necesarias, en línea con el criterio operativo de al menos un 90 % de cobertura. Este repositorio habilita tanto el análisis exploratorio de comportamiento como la estimación periódica de modelos predictivos.

En relación con el tercer objetivo, la definición y caracterización de segmentos, los resultados del modelo permiten agrupar a los clientes en rangos de riesgo Muy bajo, Bajo, Medio, Alto y Muy alto a partir de la probabilidad de baja estimada. En el conjunto de prueba, el 20 % de clientes con mayor score concentra alrededor del 70 % del churn observado, muy por encima del 40 % fijado como meta. A esto se suma el cruce con la información de motivos de baja por rubro y por plan, que muestra patrones distintos entre, por ejemplo, rubros

donde domina el cierre de local y rubros donde pesa más la competencia o el costo beneficio. Esta combinación confirma que los segmentos de alto riesgo están fuertemente asociados al abandono y que la segmentación conductual resultante es útil para el diseño de políticas comerciales focalizadas y diferenciadas según contexto.

El cuarto objetivo, referido al diseño de un portafolio de políticas por segmento, se cumple a nivel de propuesta. El proyecto entrega un conjunto inicial de reglas de acción que combina nivel de riesgo, valor económico aproximado y contexto comercial (rubro y plan). Se proponen contactos uno a uno para casos de Alto y Muy alto riesgo con alto pago mensual, campañas automatizadas para clientes de alto riesgo y menor valor, acciones enfocadas en costo beneficio y uso en rubros sensibles al precio, y monitoreo suave para riesgo Medio. Además se incorporan lineamientos específicos según los motivos de baja predominantes en cada rubro y plan, como el seguimiento sistemático de clientes bloqueados o la revisión de funcionalidades en segmentos donde la competencia es un motivo relevante. La meta de tasa de aceptación de acciones igual o superior al 25 % aún no puede evaluarse porque no se ha ejecutado un piloto controlado, por lo que este indicador se mantiene como objetivo operativo para la fase de implementación que deberá desarrollar la empresa.

El quinto objetivo, la implementación de un prototipo operativo del modelo analítico y de las políticas, también se considera alcanzado. La carpeta de uso para Customer Success, el cuaderno de scoring en Colab, el archivo de Excel de resultados y los tutoriales escritos y grabados conforman un flujo de trabajo completo y reproducible. Estos elementos permiten que el equipo ejecute el proceso de generación del datamart, aplique el modelo sobre un corte mensual y actualice la vista de resultados sin apoyo del estudiante. Además se realizaron pruebas en vivo del flujo y se dejó una primera versión del prototipo para ser utilizada y observada durante los meses siguientes, lo que traslada el modelo desde el ámbito académico a la práctica empresarial.

10.2. Conclusiones generales

El proyecto “Diseño de políticas comerciales para una empresa de tecnología para servicios de salud basado en el comportamiento de sus clientes” articula en una sola propuesta los componentes analíticos y operativos necesarios para que Reservo gestione de manera más proactiva la retención y la expansión de su cartera de clientes. A partir de un datamart mensual estructurado se construye un modelo de regresión logística calibrado que estima la probabilidad de churn a horizonte T+1 y permite derivar probabilidades a T+3, en coherencia con la dinámica mensual del negocio y con la necesidad de contar con señales tanto de corto como de mediano plazo.

Las métricas obtenidas muestran que el modelo discrimina con solidez entre clientes que se darán de baja y clientes que permanecerán activos, y que el 20 % de la cartera con mayor probabilidad estimada concentra cerca del 70 % de las bajas. Esta capacidad de focalización, combinada con la línea base económica levantada en la fase inicial, indica que reducciones moderadas en la tasa de bajas pueden traducirse en montos anuales de ingresos retenidos que son relevantes para la empresa y suficientes para justificar el esfuerzo de implementación y mantenimiento del sistema.

El prototipo operativo integra el modelo en el flujo real de trabajo mediante tres piezas principales: el script SQL que genera el datamart, el cuaderno de scoring en Google Colab y el archivo de Excel que presenta los resultados en un formato familiar para Customer Success. Sobre esta base, los equipos de Marketing, Ventas y Customer Success disponen de un repositorio de datos estructurado, de un modelo analítico validado, de segmentos de clientes definidos según riesgo, valor, rubro y plan, y de un procedimiento documentado para aplicar el modelo de forma periódica. La información de motivos de baja por rubro y plan se incorpora como insumo adicional para interpretar los segmentos y ajustar las acciones sugeridas en cada contexto, lo que refuerza el vínculo entre la salida del modelo y la experiencia de los equipos que trabajan con los clientes.

En conjunto, estos elementos permiten avanzar en el objetivo general de desarrollar un modelo de segmentación conductual que habilite políticas comerciales diferenciadas. El proyecto deja trazada una ruta clara para el trabajo posterior de la empresa: incorporar nuevas fuentes de información, como registros sistemáticos de visitas a los centros y métricas de satisfacción; profundizar en el análisis comparativo con la competencia para entender mejor ciertos patrones de baja; automatizar gradualmente el despliegue en la infraestructura propia; y diseñar pilotos que midan de manera conjunta la efectividad y el costo de las políticas de retención y expansión basadas en los scores del modelo.

De este modo, Reservo queda en posición de transformar la analítica de churn en un componente estable de su estrategia comercial, utilizando el comportamiento de sus clientes y los motivos de baja observados como eje para decidir cómo, cuándo y con qué intensidad intervenir cada relación, y conectando de forma explícita las decisiones de Customer Success con el impacto económico observado en la cartera.

Referencias

AgendaPro (2025). *AgendaPro Raises $35 Million Growth Round Led by Riverwood Capital to Give Spas, Salons, and Health & Wellness Business Owners Access to AI & Automation.* Business Wire. URL: https://www.businesswire.com/news/home/20250820309504/en/AgendaPro-Raises- Accedido: 2025-10-06.

Biblioteca del Congreso Nacional de Chile (2012). *Ley Nº 20.584: Regula los derechos y deberes que tienen las personas en relación con acciones vinculadas a su atención en salud.* Biblioteca del Congreso Nacional de Chile. Accedido en agosto de 2025.

CEPAL (2024). *ECLAC Launched Digital Development Observatory to Contribute to Latin America and the Caribbean's Digital Transformation.* Economic Commission for Latin America and the Caribbean.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., and Wirth, R. (2000). *CRISP-DM 1.0: Step-by-Step Data Mining Guide.* CRISP-DM Consortium.

Clínicas de Chile A.G. (2025). *Dimensionamiento del Sector Salud en Chile: Edición 2023.* Clínicas de Chile A.G. URL: https://www.clinicasdechile.cl/wp-content/uploads/2025/01/Dimensionamiento-2023.pdf; Accedido: 2025-10-06.

Encuadrado (2025). *Novedades julio 2025: Nuevo diseño del perfil para Centros.* Encuadrado. URL: https://www.encuadrado.com/novedades/julio-2025; Accedido: 2025-10-06.

Gupta, S., Lehmann, D. R., and Stuart, J. A. (2004). *Valuing Customers*, volume 43. Journal of Marketing Research.

Healthatom (Medilink) (2025). *Healthatom — Mejoramos la calidad y el acceso a la salud.* Healthatom SpA. URL: https://www.healthatom.com/; Accedido: 2025-10-06.

Hosmer, D. W., Lemeshow, S., and Sturdivant, R. X. (2013). *Applied Logistic Regression (3rd ed.).* Wiley.

IDB Lab and HolonIQ (2024). *Health Innovation & Technology in Latin America & the Caribbean.* Inter-American Development Bank.

Inc., S. I. (2021). *Cumulative Gains and Lift Charts (SAS Help Center).* SAS Institute.

Jain, S. (2023). *What Is a Good Customer Churn Rate?* ChartMogul. Actualizado: 11 de diciembre de 2023; Accedido: 2025-10-06.

Kumar, V. and Reinartz, W. (2018). *Customer Relationship Management: Concept, Strategy, and Tools.* Springer.

Lemmens, A. and Croux, C. (2008). *Bagging and Boosting Classification Trees to Predict Churn*, volume 45. Journal of Marketing Research.

Munar, N. (2023). *Las healthtech chilenas que están transformando el sector de la salud.* Emol — Portal Pyme.

Paredes, A. (2025). *Start-Up Chile welcomes a new generation!* Start-Up Chile.

RESERVO (2025). *Quiénes Somos*. RESERVO. Consultado en agosto de 2025.

Revista Chilena de Salud Pública (Universidad de Chile) (2025). *Telemedicina en Chile: uso, desarrollo y controversias en una red de salud pública del sur de Chile*. Universidad de Chile. Estudio cualitativo.

Superintendencia de Salud de Chile (2025). *Telemedicina y Salud Mental en Chile*. Superintendencia de Salud de Chile. Documento de trabajo; Ley N. 21.541 formaliza directrices para la práctica, seguridad de datos e interoperabilidad.

Superintendencia de Salud (Gobierno de Chile) (2025). *Chile avanza hacia los 1000 prestadores de salud acreditados en 2026: Un compromiso con la calidad y seguridad del paciente*. Superintendencia de Salud. URL: https://www.superdesalud.gob.cl/noticias/2025/04/chile-avanza-hacia-los-1000-prestadores-de-salud-acreditados-en-2026-un-compromiso-con-la-calidad-y-seguridad-del-paciente/; Accedido: 2025-10-06.

World Health Organization (2018). *Classification of digital health interventions v1.0*. World Health Organization.

Anexo A. Organigrama

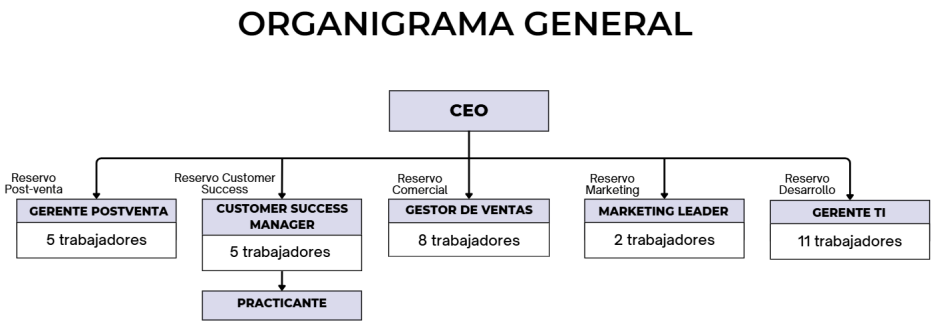

Figura A.1: Organigrama de Reservo, Agosto 2025. Fuente: elaboración propia

Anexo B. Estados del cliente

B.1.

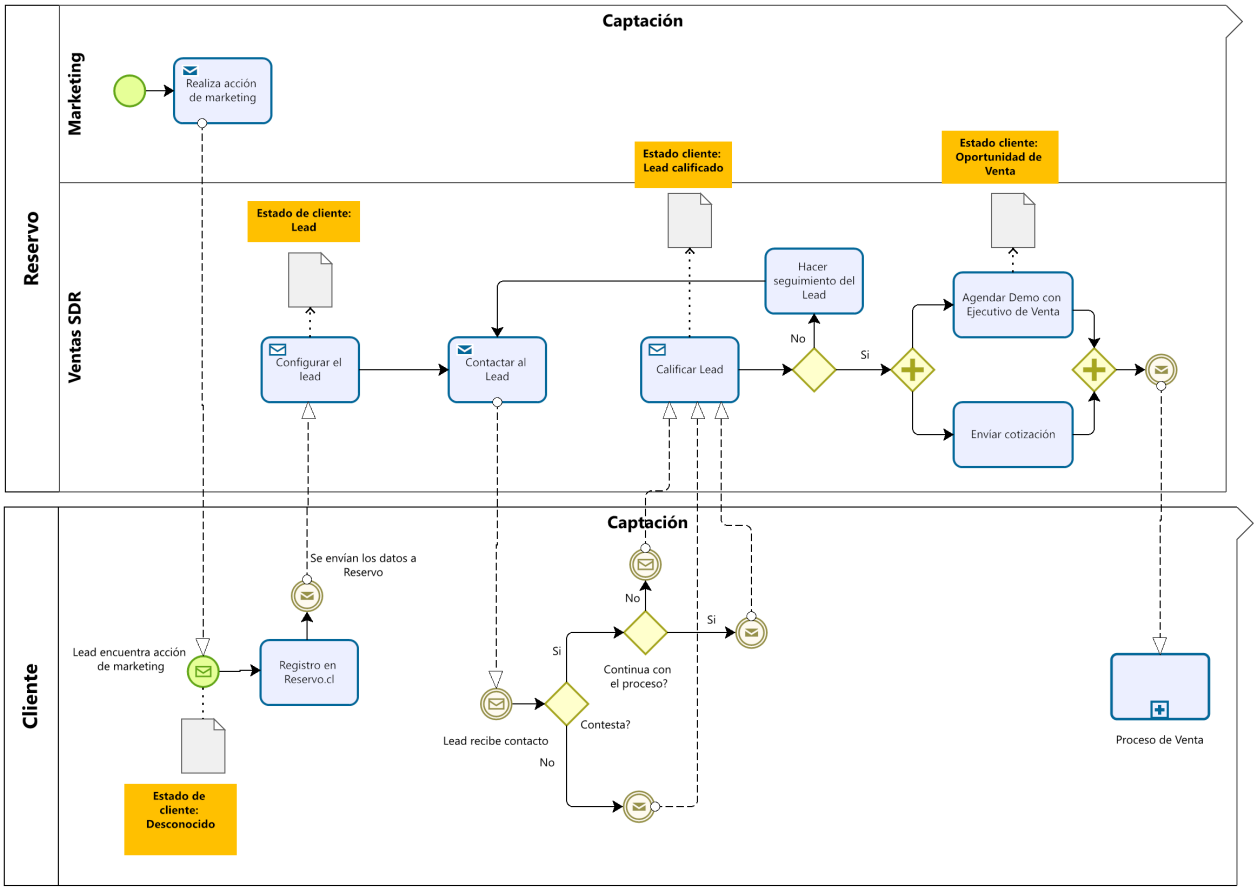

Figura B.1: Etapa de Adquisición en Reservo. Fuente: elaboración propia

B.2.

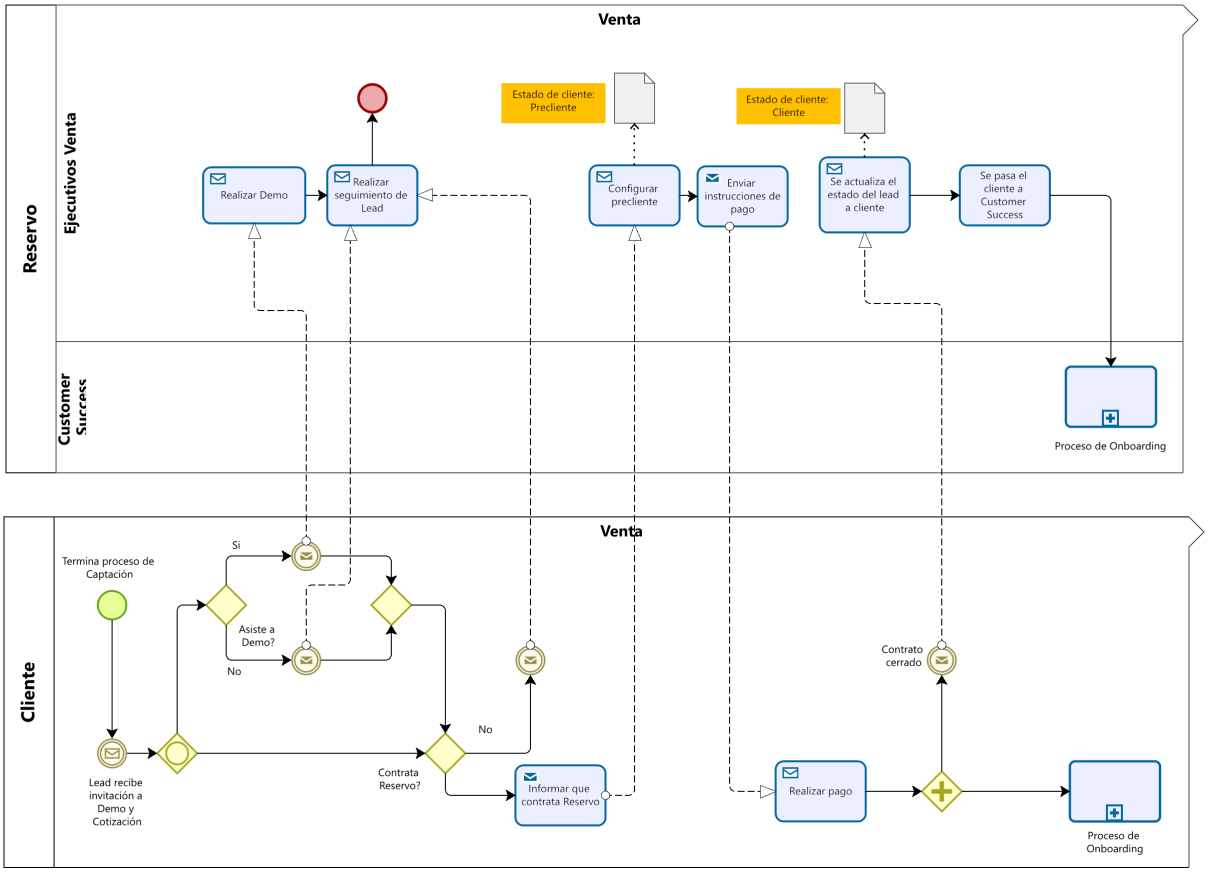

Figura B.2: Etapa de Venta en Reservo. Fuente: elaboración propia

B.3.

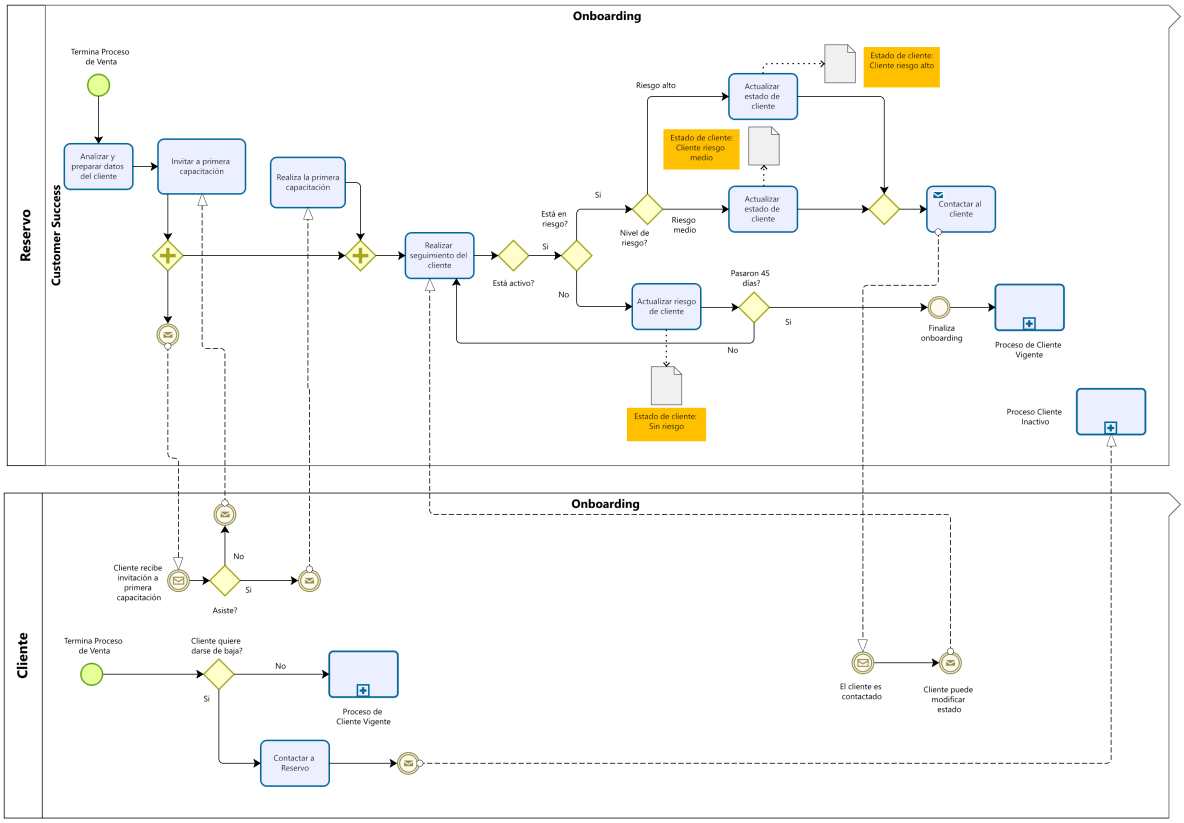

Figura B.3: Etapa de Onboarding del cliente en Reservo. Fuente: elaboración propia

B.4.

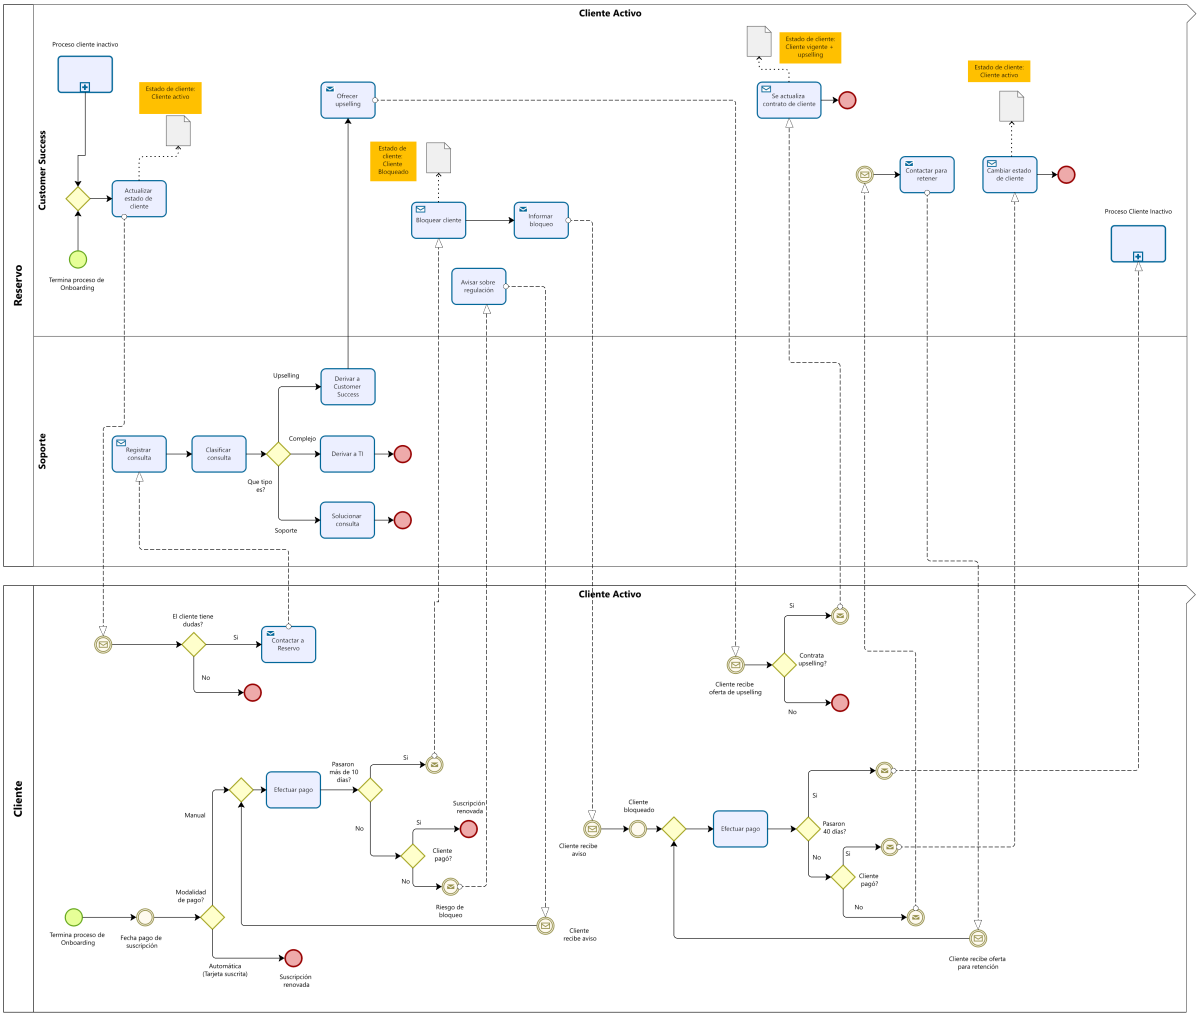

Figura B.4: Etapa de cliente activo en Reservo. Fuente: elaboración propia

B.5.

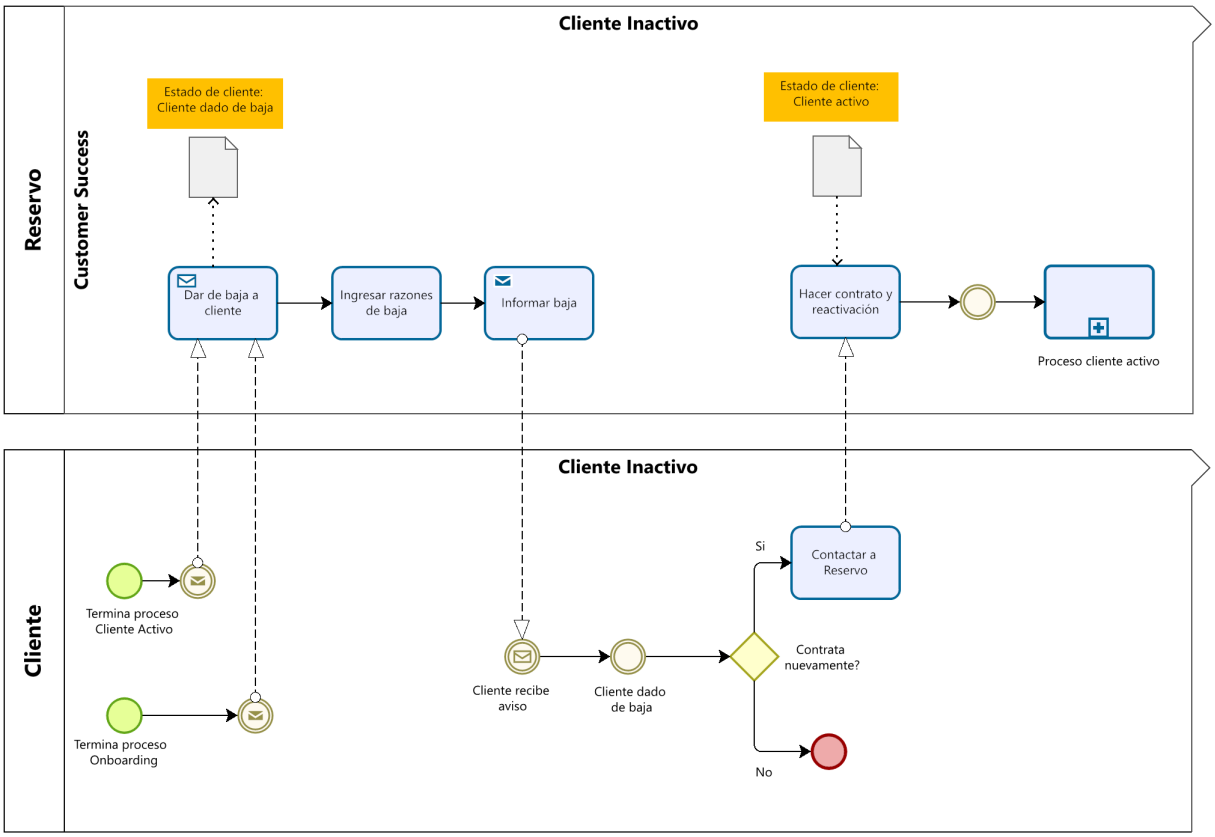

Figura B.5: Etapa de Cliente inactivo en Reservo. Fuente: elaboración propia

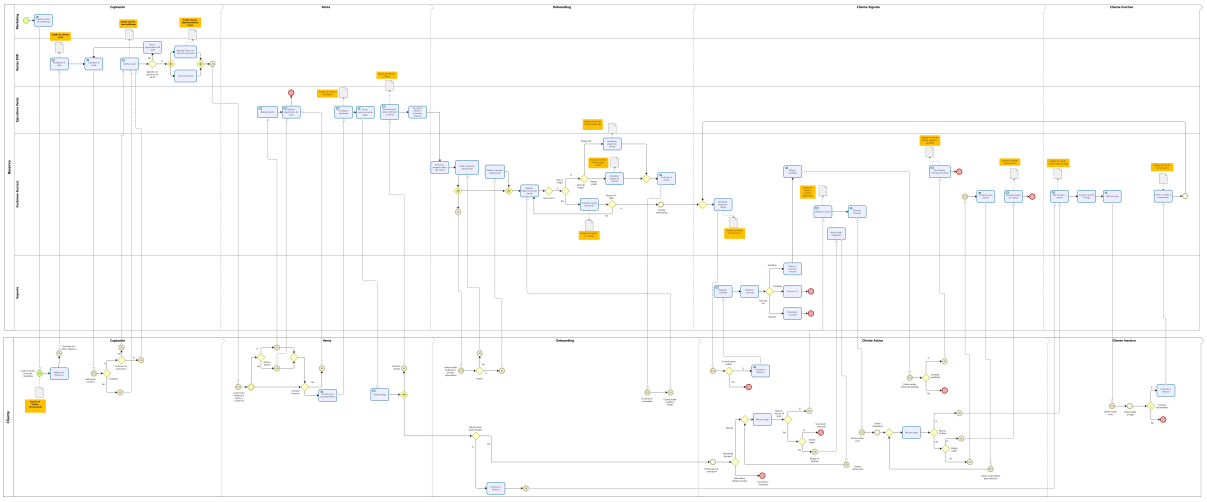

Figura B.6: Proceso completo de cliente en Reservo. Fuente: elaboración propia

Anexo C. Indicadores del proceso

Tabla C.1: Métricas asociadas a clientes. Fuente: Elaboración propia

Estado	**Definición**	**Métricas asociadas**	**Fórmula / Cálculo**
Desconocido	Persona que aún no ha interactuado con la marca.	Visitas al sitio web.	Visitas web: nº de sesiones únicas registradas en la web.
Lead	Persona que mostró interés inicial y dejó sus datos de contacto.	Costo por Lead (CPL).	$\text{CPL} = \frac{\text{Gasto en marketing}}{\text{Nº leads generados}}$
Lead calificado	Lead que ha sido validado por el equipo SDR como un cliente potencial.	Tasa de conversión a SQL (Sales Qualified Lead).	$\text{SQL rate} = \frac{\text{Nº leads calificados}}{\text{Nº leads totales}} \times 100$
Oportunidad de venta	Lead calificado que ha aceptado una demostración o propuesta formal.	Win Rate.	$\text{Win rate} = \frac{\text{Nº ventas cerradas}}{\text{Nº oportunidades}} \times 100$
Cliente nuevo	Ha contratado el servicio y se ha completado su alta en el sistema.	Costo de Adquisición de Cliente (CAC).	$\text{CAC} = \frac{\text{Costo total de Marketing y Ventas}}{\text{Nº clientes nuevos adquiridos}}$
Onboarding (0–90 días)	Cliente nuevo en el proceso de implementación y capacitación inicial.	Tasa de Activación.	$\text{Activación} = \frac{\text{Nº clientes que completan onboarding}}{\text{Nº clientes nuevos}} \times 100$
Cliente activo	Cliente que ha completado el onboarding y usa la plataforma regularmente.	Engagement Score.	Engagement = Frecuencia y profundidad de uso de funciones clave.
Cliente en riesgo	Cliente con bajo uso, quejas recurrentes o problemas de pago.	% de Clientes en Riesgo.	$\text{\% en riesgo} = \frac{\text{Nº clientes en riesgo}}{\text{Nº clientes activos}} \times 100$
Cliente en expansión	Cliente activo que contrata nuevas funcionalidades, módulos o sedes.	Net Dollar Retention (NDR).	$\text{NDR} = \frac{\text{MRR inicial + Expansión - Churn}}{\text{MRR inicial}} \times 100$
Cliente Churn	Cliente que ha cancelado su suscripción y no renueva.	Tasa de Churn.	$\text{Churn Rate} = \frac{\text{Nº clientes perdidos}}{\text{Nº clientes al inicio del período}} \times 100$
Valor de Vida del Cliente	Predicción del beneficio neto atribuido a toda la relación futura con un cliente.	Lifetime Value (LTV).	LTV = (Ticket promedio × Recurrencia) × Vida del cliente

Anexo D. Tablas de Desarrollo

D.1.

Tabla D.1: Bloqueados y actividad de citas por rubro. Fuente: elaboración propia

Rubro	**Número de bloqueados**	**Prom. citas últimos 3 meses (bloq.)**	**Prom. citas último año (act.)**
Centro de estética	9	16	449
Medicina / Salud	54	20	564
Odontología	2	39	286
Psicología / Psiquiatría	18	6	208
Salón de belleza / Barbería	6	53	544

D.2.

Tabla D.2: Bloqueados y actividad de citas por plan. Fuente: elaboración propia

Plan	**Número de bloqueados**	**Prom. citas últimos 3 meses (bloq.)**	**Prom. citas último año (act.)**
Individual	36	11	79
Básico	39	16	470
Reservo	16	35	575
Enterprise	3	49	2 524

D.3.

Tabla D.3: Promedio de mensualidad por rubro (CLP). Fuente: elaboración propia

Rubro	**Promedio de mensualidad**
Medicina / Salud	$ 62.566
Psicología / Psiquiatría	$ 54.731
Centro de estética	$ 51.366
Salón de belleza / Barbería	$ 44.906
Odontología	$ 40.950
Total general	**$ 58.700**

D.4.

	Cantidad de Nulos	% de Nulos
dias_desde_ultimo_bloqueo	59785	0.95
recencia_uso_dias	29130	0.46
rubro	22901	0.37
plan_reservo_id	20528	0.33
plan_nombre	20528	0.33
arpa_proxy	3333	0.05
id_cliente	0	0.00
mes_corte	0	0.00
pais	0	0.00
citas_30d	0	0.00
tenure_meses	0	0.00
tendencia_90d	0	0.00
citas_60d	0	0.00
bloqueos_90d	0	0.00
cambios_estado_90d	0	0.00
baja_previa	0	0.00
churn_T1	0	0.00

Figura D.1: Porcentaje de nulos por variable. Fuente: elaboración propia

D.5.

```
Tipos de datos de las variables:
id_cliente                            int64
mes_corte                    datetime64[ns]
pais                                 object
plan_reservo_id                     float64
plan_nombre                          object
rubro                                object
arpa_proxy                          float64
tenure_meses                          int64
citas_30d                             int64
citas_60d                             int64
recencia_uso_dias                   float64
tendencia_90d                         int64
bloqueos_90d                          int64
cambios_estado_90d                    int64
dias_desde_ultimo_bloqueo           float64
baja_previa                           int64
churn_T1                              int64
dtype: object
```

Figura D.2: Tipos de datos de las variables. Fuente: elaboración propia

D.6.

	count	mean	std	min	25%	50%	75%	max
id_cliente	62696.00	3317.78	1942.11	24.00	1727.00	3177.00	4879.25	7449.00
plan_reservo_id	42168.00	43.92	31.19	1.00	33.00	34.00	35.00	214.00
arpa_proxy	59363.00	48780.48	67965.26	1.00	30000.00	40000.00	60000.00	2370000.00
tenure_meses	62696.00	38.03	26.54	0.00	17.00	35.00	54.00	130.00
citas_30d	62696.00	213.24	548.22	0.00	0.00	2.00	209.00	13164.00
citas_60d	62696.00	421.90	1085.57	0.00	0.00	5.00	412.00	25716.00
recencia_uso_dias	33566.00	4.48	11.56	1.00	1.00	1.00	2.00	90.00
tendencia_90d	62696.00	6.27	103.23	-4350.00	0.00	0.00	3.00	3610.00
bloqueos_90d	62696.00	0.15	0.53	0.00	0.00	0.00	0.00	7.00
cambios_estado_90d	62696.00	1.65	2.88	0.00	0.00	0.00	3.00	50.00
dias_desde_ultimo_bloqueo	2911.00	49.29	90.77	1.00	10.00	18.00	29.00	668.00
baja_previa	62696.00	0.01	0.12	0.00	0.00	0.00	0.00	1.00
churn_T1	62696.00	0.01	0.11	0.00	0.00	0.00	0.00	1.00

Figura D.3: Estadísticas descriptivas de variables numéricas. Fuente: elaboración propia